真实 API 小样本测试 | 技术评估报告

决策模型准确率与响应速度对比

阿里云百炼 decision-model-preview
Microsoft Decision-1（通过 OpenRouter / Azure）

测试时间：2026-10-11 18:37:58 - 18:38:37（北京时间）

本次结果：微软更准，阿里云百炼更快

准确率：微软领先 8.33 个百分点。微软 100.00%，阿里云百炼 91.67%，即微软多答对 1 道题（12 道题中）。
响应速度：阿里云百炼领先。相较微软，P50 耗时降低 80.45%（少等 442.9 ms），P95 耗时降低 56.91%（少等 486.2 ms）。
请求成功与重复稳定性：两家持平。正式请求均无失败，后两轮分类均与首轮一致。

核心指标	阿里云百炼	微软 / OpenRouter	本次优势 / 差距
首轮正确数 / 独立题数	11 / 12	**12 / 12**	微软多对 1 题
首轮准确率（越高越好）	91.67%	**100.00%**	微软高 8.33 个百分点
客户端 P50（越低越好）	**107.7 ms**	550.6 ms	阿里云百炼低 80.45%
客户端 P95（越低越好）	**368.1 ms**	854.4 ms	阿里云百炼低 56.91%
正式请求失败率（越低越好）	0%（0 / 36）	0%（0 / 36）	持平
重复分类一致率（越高越好）	100%（24 / 24）	100%（24 / 24）	持平

浅绿色单元格 = 本次实测更优；持平项不着色。耗时降低比例以微软耗时为分母；准确率差使用百分点。

如何选择：就本次表现看，重视判断正确性可优先进一步验证微软；重视响应速度可优先进一步验证阿里云百炼。两家各有优势，本报告不设未经验证的综合赢家。

适用范围：仅 12 条人工科学语境示例，准确率差异来自 1 题，配对区间包含零，尚不能证明总体准确率谁更高。速度比较覆盖客户端完整接入路径，不等于模型内部计算速度。

阅读导航

第 2-5 页：四组图解；第 6 页：设计与样本；第 7 页：准确率；第 8-9 页：延迟；第 10 页：概率与复核；第 11 页：错误案例；第 12-13 页：逐题审计；第 14 页：下一轮方案；第 15 页：复现与资料。

数据来源：本地真实请求记录。模型不是本地模拟模式；示例内容是人工构造，尚未运行 PubMedQA 正式评测。

图解 A / 一次测试如何产生两类结论

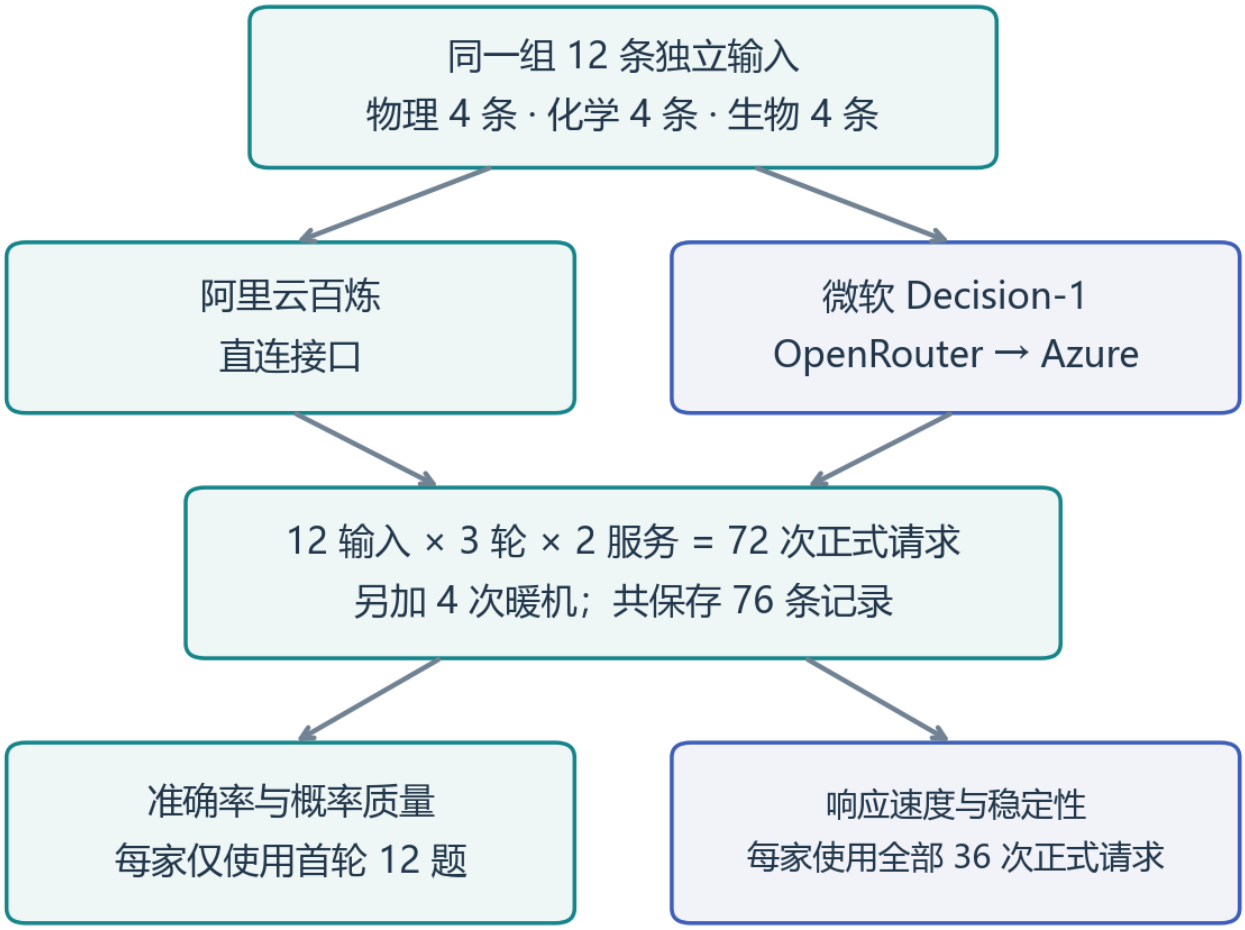


图 A. 同一组题目配对调用两家服务；评分与计时使用不同的统计口径。

先分清“题数”和“请求数”

12 道题重复三次，仍然只有 **12 个独立输入**。重复请求可以观察延迟与稳定性，但不能把准确率样本量写成 36。

例如 demo-002 在三轮都回答错误，代表同一道题上的稳定错误；它在首轮准确率中只计一次。本报告先用相同输入保证可比，再按各指标的定义选择记录。

暖机用于预热连接与服务链路，其 4 条记录单列，不进入准确率和主要延迟统计。

图解 B / 把准确率还原成一道道题

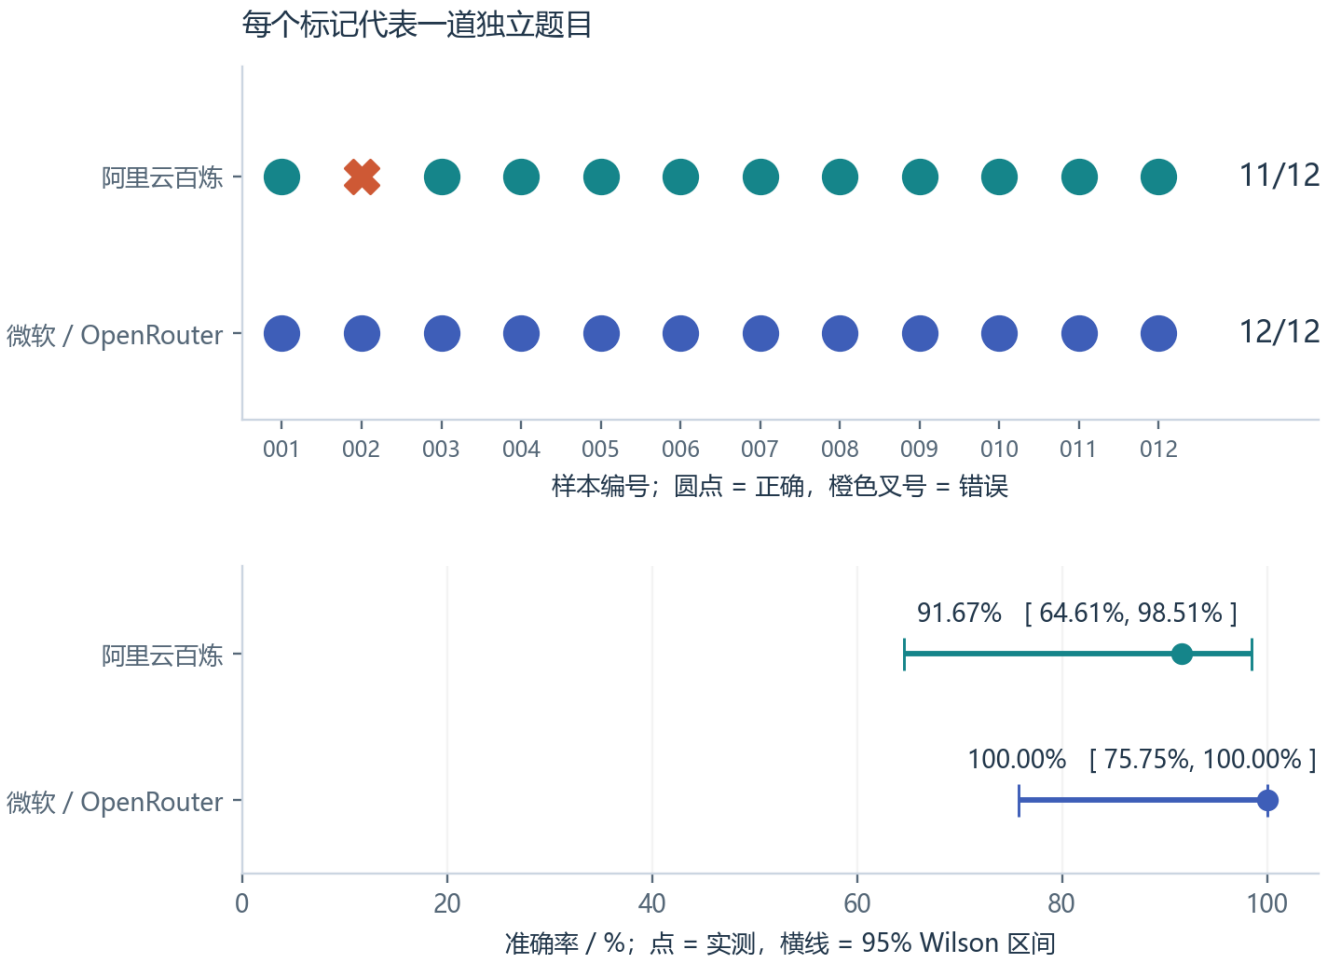


图 B. 上图展示逐题正确性，下图显示首轮准确率与 Wilson 区间；均使用每家 12 个独立输入。

91.67% 与 100% 的差别来自一道题

阿里云百炼 11/12，微软 12/12。每增减一道正确题，准确率就变化 **8.33 个百分点**；本次观测差异全部来自 demo-002。

横线较长说明小样本估计仍不精确。12/12 的实测结果不意味着模型以后不会出错，也不意味着在物理、化学、生物三个领域都达到 100% 准确率。

Wilson 区间展示单家比例的不确定性；两家优劣应查看同题配对比较。本次配对差的 95% bootstrap 区间包含零，详见第 7 页。

图解 C / 响应速度应当怎样阅读

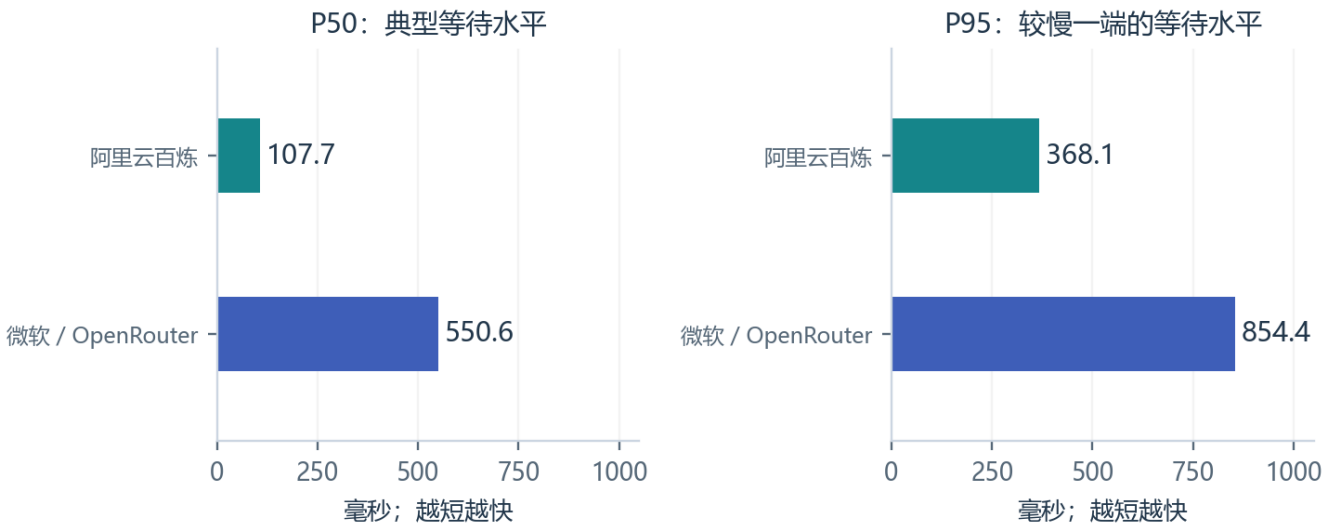


图 C1. 横轴从零开始，两图使用同一刻度。每家 n=36 次正式请求，标注为实测分位数。

读数	通俗含义	本次分位数比值
P50	把耗时排序，位于中间的水平	微软 / 阿里云百炼 ≈ 5.11
P95	约 95% 请求耗时所在的上界水平	微软 / 阿里云百炼 ≈ 2.32

小样本分位数采用线性插值，因此 P95 不一定恰好是某个请求的耗时；它不是最长耗时或服务承诺。

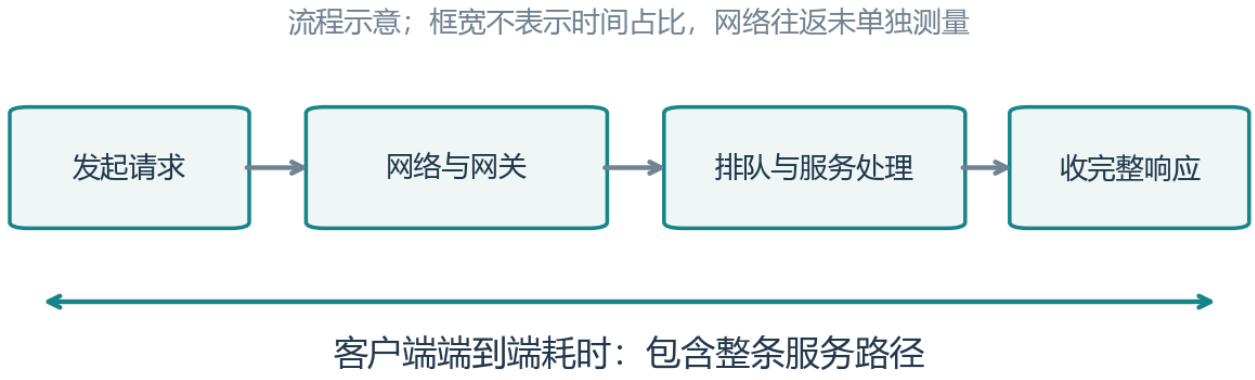


图 C2. 计时边界示意：对比的是从当前客户端感受到的完整服务响应。

两家走不同接入路径：阿里云百炼为直连，微软经 OpenRouter 转至 Azure。没有分段计时证据，因此不能把上述比值解释为模型内部计算速度相差多少倍。

图解 D / 高置信错误为什么值得关注

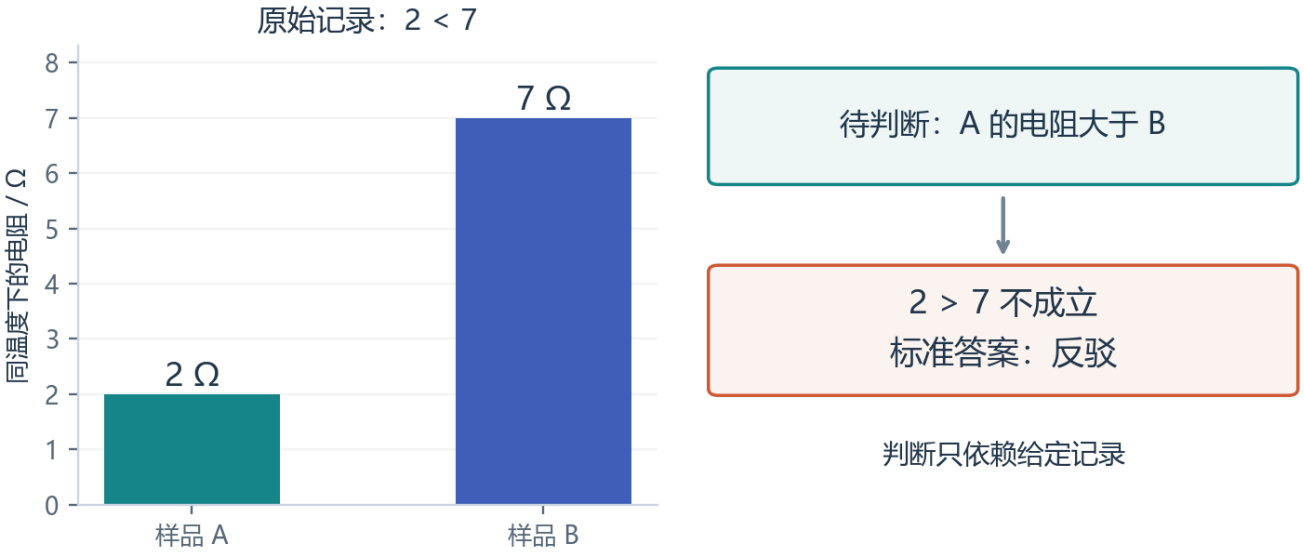


图 D1. 将 demo-002 的文字记录画成柱形图，结论与证据的冲突就更容易看清。

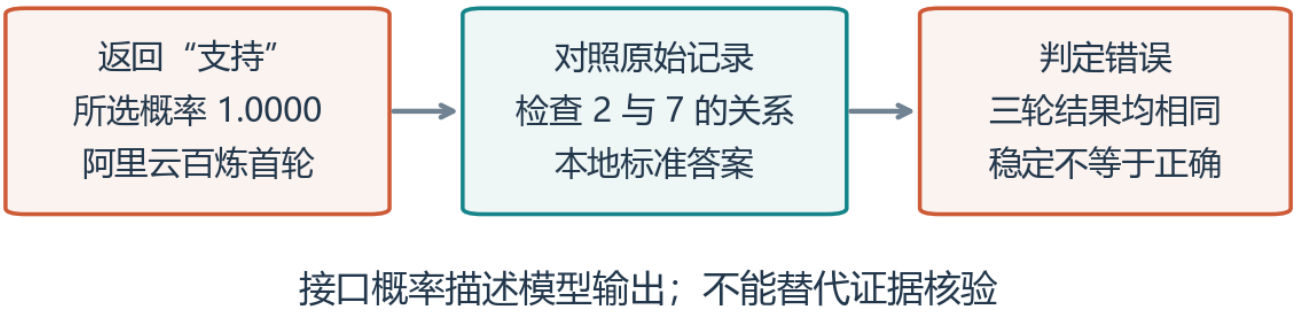


图 D2. 将模型输出与证据核验分开：很高的返回概率也可能伴随错误。

阿里云百炼首轮将“支持”的概率返回为 1.0000，却与给定数值冲突；微软首轮返回“反驳”，所选类别概率约为 0.99857。这只描述本题上的表现，不能推广为任何模型永远可靠或不可靠。

如何用于科学项目

对数值大小、单位和阈值等可计算条件，先做确定性校验；对证据缺失或模型与规则冲突的案例，交由人工复核。阈值需在独立数据上验证，不能仅凭这 12 道题设置。

01 / 测试设计与数据范围

项目	本次实际配置
独立输入 / 学科	12 条；物理、化学、生物各 4 条
标签分布	支持、反驳、信息不足各 4 条
请求结构	每个输入 1 个 choice 问题，固定 3 个选项
样本长度	state 与 questions 的 JSON 长度 262-284 字符
重复次数 / 并发	3 轮；并发 1；每个服务 2 次暖机
正式 / 暖机请求	72 次正式 + 4 次暖机 = 76 次已记录请求
随机与请求策略	种子 42；每轮随机样本顺序；每题随机服务先后
连接与重试	每个服务复用 Session；无自动重试；请求后停顿 0.1 秒
超时与计时	连接/读取等待 60 秒；完整 HTTP 响应体到达后停止计时

同题配对，而非比较各厂商宣传数字

两家得到相同的业务状态、问题说明和选项描述。标准答案保存在 expected 字段，仅供本地评分；请求构造显式只发送 model、state、questions。本次 OpenRouter 未指定 provider.only，实际成功响应记录的上游为 Azure。

评分与延迟采用不同样本口径

准确率、Macro-F1、混淆矩阵和校准指标只使用第 1 轮的 12 个独立输入。延迟使用全部 3 轮共 36 次正式请求 / 服务。后两轮只用于延迟和重复稳定性，不能将答题样本量扩大为 36。暖机与此前连接检查不计入正式结果。

样本代表性

题目为中文短文本，重点是记录与结论的支持关系、简单数值大小比较、缺失证据和否定信息。它们并非经过独立专家验证的科学能力基准，也不覆盖长论文、多模态、开放式推理、noul、score 或高并发场景。

运行总墙钟时间约 38.85 秒，包含暖机与请求间停顿；不能用 72 / 38.85 作为任一家服务的最大吞吐量。

02 / 准确率、分类误差与统计区间

指标（首轮 n=12）	阿里云百炼	微软 / OpenRouter
准确率	91.67%	100.00%
95% Wilson 区间	64.61% - 98.51%	75.75% - 100.00%
合并三类 Macro-F1	0.9153	1.0000
物理 / 化学 / 生物正确数	3/4 · 4/4 · 4/4	4/4 · 4/4 · 4/4

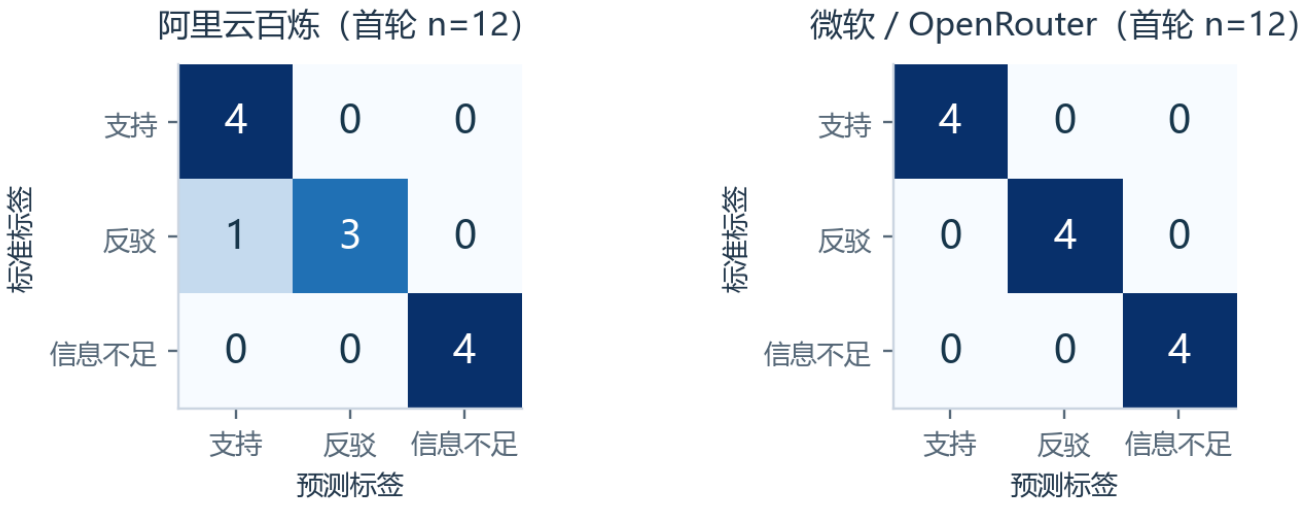


图 1. 三个学科采用同一标签语义，因此可以合并混淆矩阵。唯一误分类为“反驳”被预测成“支持”。

阿里云百炼“支持”类别精确率为 4/5 = 80%，召回率为 4/4 = 100%；“反驳”召回率为 3/4 = 75%；“信息不足”召回率为 4/4 = 100%。微软在本次样本中三类均全部正确。

不能仅凭 100% 宣称模型更强

配对差定义为“阿里云百炼准确率 - 微软准确率”：观察值 **-8.33 个百分点**，按独立输入进行 2,000 次配对 bootstrap，95% 区间为 **[-25.00, 0.00] 个百分点**。区间包含零；只有 1 个分歧样本，检验效能很低。

作为补充核查，两家分歧的配对计数为 0 对 1，双侧精确 McNemar 检验 p=1.00。该结果不证明两家能力相等，只说明这批样本不足以建立可靠的总体优劣结论。

合并 Macro-F1 按整体三类计算；它不同于先计算三个学科的 Macro-F1 再平均。Wilson 和 bootstrap 依赖抽样假设，无法修正人工选题产生的代表性偏差。

03 / 客户端延迟与响应分布

统计量（ms；n=36 / 服务）	阿里云百炼	微软 / OpenRouter
最小值	96.9	496.2
均值	145.5	600.8
P50	107.7	550.6
P90	365.8	757.9
P95	368.1	854.4
最大值	388.6	1022.8

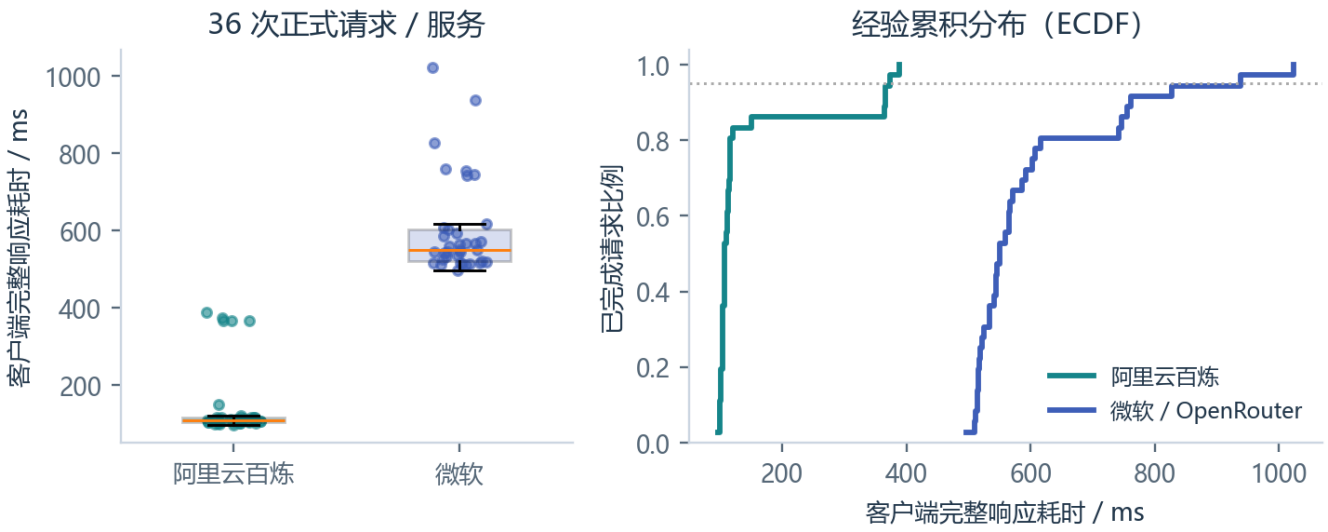


图 2. 左：逐请求散点与箱线图；右：经验累积分布。36 个请求来自重复输入，不等于 36 个独立业务样本。

本次所有 36 次阿里云百炼正式请求均低于 389 ms；所有微软正式请求均高于 496 ms，两组观察范围没有重叠。这个现象说明当前客户端和接入条件下存在明显体验差异，但不足以推断其它地域、时段或负载下的结果。

计时边界

起点在 Python 发起 HTTP 请求之前，终点在完整响应体接收之后，排除 JSON 解析、本地打分和请求后的 0.1 秒停顿。包括网络往返、可能的连接建立、网关、排队和服务处理。服务端 latency_ms 即便存在也不参与横向对比，不与客户端耗时相减估算纯网络耗时。

本次无失败和超时，成功请求与全部尝试的延迟分位数相同；后续若有失败，必须同时展示失败率，以免成功子集形成选择偏差。

04 / 轮次、暖机与同题延迟

轮次（每家 12 次）	阿里云百炼 P50 / P95 ms	微软 P50 / P95 ms
1	133.4 / 380.0	562.4 / 870.6
2	104.3 / 112.2	548.2 / 837.2
3	107.3 / 118.2	539.2 / 790.4

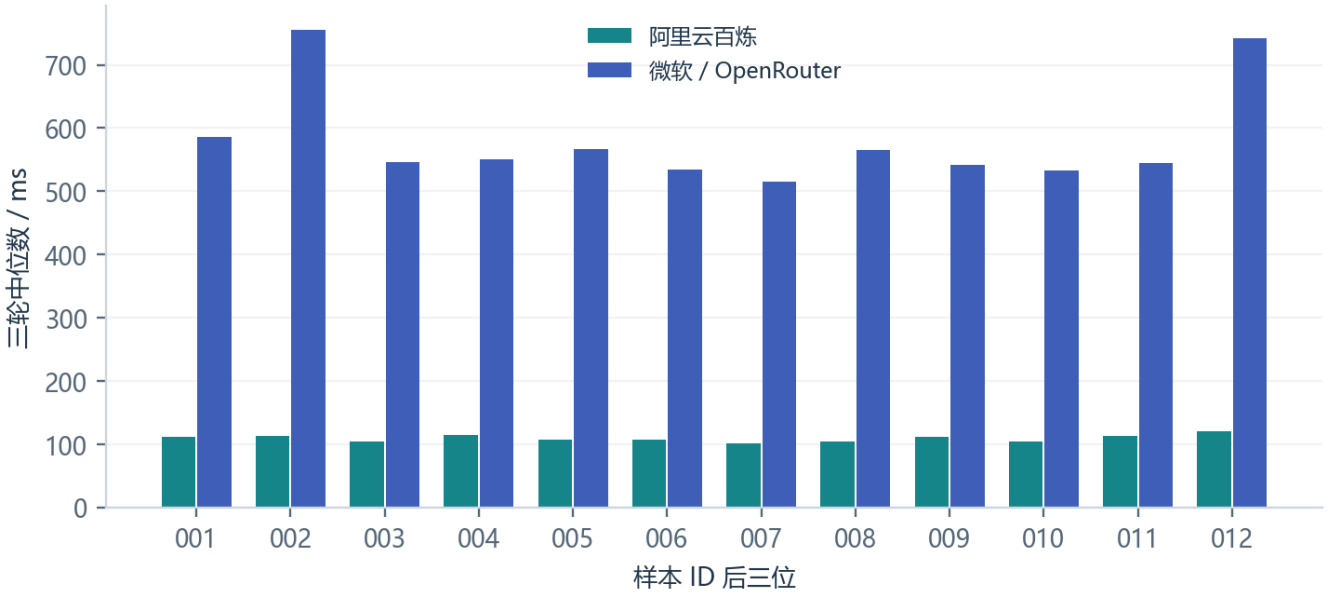


图 3. 同一输入在三轮中的耗时中位数。横轴对应附录样本编号；这不是专业领域整体速度排名。

观察到的轮次变化

阿里云百炼首轮 P95 约 380.0 ms，后两轮分别约 112.2 和 118.2 ms；微软三轮 P50 分别约 562.4、548.2、539.2 ms。后续轮次的变化可能与连接状态、云端缓存、负载或路由有关；本次未控制这些因素，不能确认单一原因。

已记录暖机（ms）	第 1 次	第 2 次
阿里云百炼	680.4	108.6
微软 / OpenRouter	2562.7	911.0

两家已预热的 Session 在正式请求中复用。暖机时间单列并排除主要延迟指标；暖机本身也不等于完全无缓存的首次调用，因为此前做过连接检查。重复完全相同的输入可能命中服务缓存，后续正式研究应分开设计首次出现输入与重复输入两种工作负载。

05 / 概率质量与人工复核策略

首轮合并指标（n=12）	阿里云百炼	微软 / OpenRouter
Brier score（各类平方误差之和）	0.176367	0.001915
ECE（10 个等宽分箱）	0.100000	0.010036
概率分布有效数	12 / 12	12 / 12

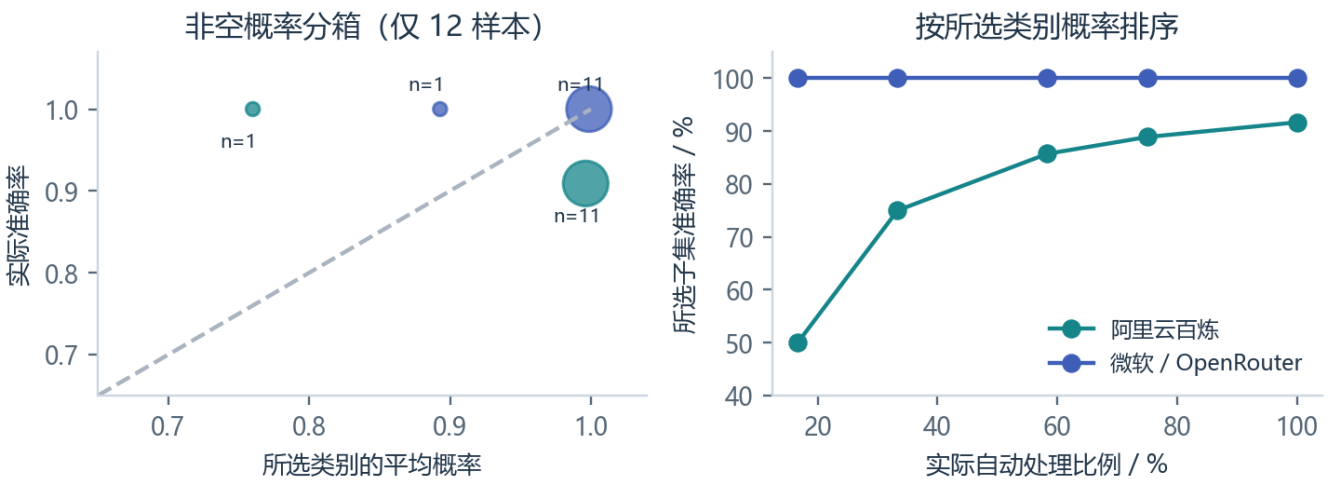


图 4. 两项指标均使用“所选类别的概率”，不直接比较厂商自定义 confidence。分箱点大小与样本数有关。

Brier 和 ECE 越低，说明在当前标签样本上预测概率与结果越一致。但本次只有 12 题、概率高度集中，ECE 对分箱很敏感；这些数值不能证明模型在真实科学数据上已完成可靠校准。阿里云百炼的高置信错误对 Brier 影响很大。

目标自动处理比例	实际纳入数 / 比例	阿里云百炼子集准确率	微软子集准确率
40%	4 / 12 = 33.33%	75.00%	100.00%
80%	9 / 12 = 75.00%	88.89%	100.00%
100%	12 / 12 = 100%	91.67%	100.00%

小样本下按 floor(目标比例 × 12) 取整，因此“80%”实际只接受 9 条。阿里云百炼错误题的返回概率为 1.0，会排在高概率端；仅过滤低概率样本无法移除它。并列概率按样本 ID 排序，这会影响小样本覆盖率曲线，不能把曲线当成已验证的上线规则。

正式阈值需在独立开发集选择，再在未调参测试集验证；模型返回概率不是科学命题为真的客观概率。

06 / 唯一错误案例：数值反驳被判为支持

样本 demo-002

结论：样品 A 的电阻大于样品 B。
记录：同温度下，A 电阻 2 Ω，B 电阻 7 Ω。
标准答案：反驳（refute）。在相同测量条件下 2 小于 7，与“A 大于 B”直接冲突。

服务 / 首轮	输出	P(支持)	P(反驳)	confidence
阿里云百炼	支持	1.000000	0.000000	1.000000
微软	反驳	0.000261	0.998570	0.997855

轮次	阿里云百炼输出 / 正确性	微软输出 / 正确性	阿里云百炼 / 微软耗时 ms
1	支持 / 错误	反驳 / 正确	366.3 / 559.0
2	支持 / 错误	反驳 / 正确	113.0 / 755.0
3	支持 / 错误	反驳 / 正确	99.8 / 760.8

重复稳定，不等于可靠正确

两家后两轮相对首轮的分类一致率均为 24/24。阿里云百炼这道题的三次输出却都错误，因此“重复一致”只能描述输出稳定性，不能替代准确率，也不能将高 confidence 作为跳过核验的充分理由。返回的 1.0 是接口数值，仍可能涉及输出精度，不代表客观上的绝对确定。

可以推断什么，不能推断什么

可以确认：当前模型、提示词和输入表示组合在该题上出现稳定误判。不能仅由答案推断模型内部推理过程，或断定是中文能力、数字处理、指令理解中的哪一环导致。接口没有提供可用于定位原因的书面推理。

下一轮有针对性的排查

固定其它条件，构造 A<B、A=B、A>B 以及缺失 B 的平衡样本；交换实体名称、选项顺序和数值位置，分别测试中文与英文。对大小关系先用确定性代码计算，作为基线与约束；新增变体应作为诊断集，不回填当前测试集来夸大改进。

07 / 逐题审计：样本 001-006

每题展示原始结论、记录、本地标准答案和首轮输出。P 为所选类别概率，C 为接口 confidence；二者含义不同。

demo-001 | 物理 | 标准：支持

结论：样品 A 的电阻大于样品 B。
记录：同温度下，A 电阻 8 Ω，B 电阻 3 Ω。

阿里云百炼：支持；P=1.0000，C=1.0000
微软：支持；P=0.9998，C=0.9997

demo-002 | 物理 | 标准：反驳

结论：样品 A 的电阻大于样品 B。
记录：同温度下，A 电阻 2 Ω，B 电阻 7 Ω。

阿里云百炼：支持；P=1.0000，C=1.0000
微软：反驳；P=0.9986，C=0.9979

demo-003 | 物理 | 标准：信息不足

结论：样品 A 的电阻大于样品 B。
记录：测得样品 A 电阻 8 Ω，未测量 B。

阿里云百炼：信息不足；P=0.7600，C=0.6300
微软：信息不足；P=0.9997，C=0.9995

demo-004 | 物理 | 标准：支持

结论：本次模拟已满足残差收敛标准。
记录：残差收敛标准为低于 1e-6；最终残差为 2e-8。

阿里云百炼：支持；P=1.0000，C=1.0000
微软：支持；P=0.9990，C=0.9984

demo-005 | 化学 | 标准：支持

结论：在记录的条件下，催化剂 X 的产率高于 Y。
记录：相同反应条件下，X 的产率 80%，Y 的产率 60%。

阿里云百炼：支持；P=1.0000，C=1.0000
微软：支持；P=0.9998，C=0.9997

demo-006 | 化学 | 标准：反驳

结论：样品中检测到氯离子。
记录：检测报告明确记录：氯离子检测结果阴性。

阿里云百炼：反驳；P=0.9900，C=0.9900
微软：反驳；P=0.9995，C=0.9992

08 / 逐题审计：样本 007-012

每题展示原始结论、记录、本地标准答案和首轮输出。P 为所选类别概率，C 为接口 confidence；二者含义不同。

demo-007 | 化学 | 标准：信息不足

结论：催化剂 X 比 Y 更耐长期使用。
记录：只记录了 X 与 Y 的首次反应产率，没有长期测试。

阿里云百炼：信息不足；P=1.0000，C=1.0000
微软：信息不足；P=0.9998，C=0.9997

demo-008 | 化学 | 标准：反驳

结论：反应在 25 摄氏度完成。
记录：实验日志：恒温 60 摄氏度，反应结束；未进行 25 摄氏度实验。

阿里云百炼：反驳；P=0.9800，C=0.9700
微软：反驳；P=0.9914，C=0.9870

demo-009 | 生物 | 标准：支持

结论：处理组平均细胞数高于对照组。
记录：处理组平均细胞数 120，对照组平均细胞数 80。

阿里云百炼：支持；P=1.0000，C=1.0000
微软：支持；P=0.9998，C=0.9998

demo-010 | 生物 | 标准：反驳

结论：实验使用了小鼠。
记录：实验记录明确说明仅使用酵母，未使用动物。

阿里云百炼：反驳；P=1.0000，C=1.0000
微软：反驳；P=0.9995，C=0.9993

demo-011 | 生物 | 标准：信息不足

结论：处理可提高细胞存活率。
记录：记录只给出了处理组的荧光强度，没有存活率数据或对照。

阿里云百炼：信息不足；P=1.0000，C=1.0000
微软：信息不足；P=0.9998，C=0.9996

demo-012 | 生物 | 标准：信息不足

结论：处理会改变基因表达量。
记录：本实验只测量了培养液 pH，没有测量基因表达。

阿里云百炼：信息不足；P=0.9900，C=0.9900
微软：信息不足；P=0.8930，C=0.8394

09 / 结论边界与下一轮正式评估

本报告已经支持的判断

两条真实服务链路已跑通；在当前中文短文本、单问题、串行负载下，阿里云百炼客户端延迟更低；微软在这批示例上少错一道题。所有正式请求均成功返回有效结构，且分类结果在三轮内稳定。

尚未解决的问题

限制	影响
只有 12 条人工示例	不能估计真实科研任务的总体水平；3 个学科各 4 条更不足以排名
输入只有 262-284 字符	不能外推到长摘要、全文、多证据或复杂数值推理
一次运行、一个客户端	不能区分接入路径与模型计算；无法代表长期尾延迟或 SLA
同题重复、缓存未控制	后续轮次可能获得缓存或暖连接收益；不属于纯冷请求对比
概率高且类别简单	校准曲线不稳定，不能直接制定高风险自动处理阈值
模型别名与路由可能变化	需要保存实际 served_model、provider、时间和原始输出

建议的下一轮实验

数据：使用 500 条独立、标注可靠的科学任务；文献判断可从 PubMedQA 起步，保留不含答案结论的上下文。按论文/实验对象分组划分开发集与测试集，补充近期未用于调参的专业样本。

控制：固定提示词、选项语义、输入语言、阈值和版本；区分短/中/长输入。首次出现输入与重复输入分别统计，至少在多个时段复测；并发 1 与并发 4 分开运行。

指标：准确率、Macro-F1、关键类别漏判、Brier、风险-覆盖率、P50/P95 和失败率。增加规则系统/专业分类器基线；配对比较按独立实验对象重采样。不要用测试集结果继续调提示词。

建议运行：python benchmark.py --env-override run --dataset data\pubmedqa\test.jsonl --limit 500 --rounds 3 --warmup 10 --concurrency 1

先执行 prepare-pubmedqa。该命令默认生成自定义分层划分，不能作为 PubMedQA 官方榜单成绩。以上是建议，尚未执行，也不属于本报告的测量结果。

10 / 复现、指标定义与数据来源

复现本次小样本测试

```
cd C:\decision\decision-benchmark
python benchmark.py --env-override run --rounds 3 --warmup 2 --concurrency 1
```

本次连接检查发现旧进程环境变量覆盖了 .env 中的新阿里云百炼密钥；使用显式 --env-override 后成功。该选项只改变本次进程配置优先级，不修改系统环境变量。修复后 19 项自动测试通过。此过程不纳入 72 次正式请求统计。

复现信息	记录
实际微软模型	microsoft/microsoft-decision-1-20261009
实际阿里云百炼模型	decision-model-preview（返回未提供更细快照号）
地域 / 路由	阿里云百炼北京；微软由 OpenRouter 转 Azure，响应未给出具体推理地域
运行环境	Windows 10 build 19045；Python 3.12.7；requests 2.32.5
随机种子 / bootstrap	42 / 2,000 次；按输入 ID 配对重采样

指标定义

Accuracy = 正确数 / 独立测试题数；Macro-F1 = 各标签 F1 的算术平均；Brier = 各类别预测概率与真实 one-hot 标签的平方差之和，再对样本取平均；ECE = 各概率分箱的概率-准确率绝对差按样本数加权。分位数采用排序后的线性插值。

原始证据与审计

C:\decision\decision-benchmark\results\20261011T103758_581181Z

run.json：运行配置与时间；dataset.jsonl：12 条实际输入和本地标准答案；requests.jsonl：76 条含暖机的完整记录；summary.json：原程序统计。PDF 中的合并 Macro-F1、合并校准、按轮次延迟和精确 McNemar 为基于同一记录的补充计算。

dataset.jsonl SHA-256: f3cce6261ac63ce3d4bc22b18fd7af00
9a45142d6f039ff88d708da791cd9d88

requests.jsonl SHA-256: 59589d19627e1feff7a71ea761b2e92e
cda9ddf29d22f026b974a59c21e605c9

方法与接口参考

阿里云百炼决策接口：https://help.aliyun.com/zh/model-studio/decision-model-api

OpenRouter 微软模型页：https://openrouter.ai/microsoft/microsoft-decision-1

PubMedQA（Jin 等，2019）：https://aclanthology.org/D19-1259/

概率校准（Guo 等，ICML 2017）：https://proceedings.mlr.press/v70/guo17a.html

本报告未引用厂商宣传性能作为实测结果；所有比较数字均来自指定本地运行。未包含 API Key、.env 内容或账户密钥。