真实 API 四方测试 技术评估报告

四方模型准确率与响应速度对比

阿里云百炼 · 微软 Decision-1 · Qwen3.5-9B · Jev 1.13

2026-10-12 18:14:54 - 18:18:08（北京时间）

准确率并列第一：微软 Decision-1、Jev 1.13；最低时延：阿里云百炼

准确率：微软 Decision-1、Jev 1.13 均为 12/12（100%），比百炼与 Qwen 高 8.33 个百分点，多答对 1 题。

响应速度：阿里云百炼 的 P50 为 93.0 ms，比 Jev 1.13 低 88.92%，比最慢的 Qwen3.5-9B 低 95.29%。

两家满分服务之间：Jev 1.13 的 P50 比 微软 Decision-1 低 36.77%（少等 488.5 ms），P95 低 13.51%。

指标	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
首轮正确数	11 / 12	**12 / 12**	11 / 12	**12 / 12**
准确率 越高越好	91.67%	**100.00%**	91.67%	**100.00%**
Macro-F1 越高越好	0.9153	**1.0000**	0.9153	**1.0000**
P50 ms 越低越好	**93.0**	1328.5	1975.4	839.9
P95 ms 越低越好	**110.1**	1643.0	4553.5	1421.1
正式请求成功数	36 / 36	36 / 36	36 / 36	36 / 36
重复分类一致率	100.00%	100.00%	100.00%	100.00%

浅绿色表示该行最优；并列最优同时标色，四家持平项不标色。百分比降幅以被比较服务的耗时为分母。

若同时看准确率与等待时间，Jev 1.13 与 微软 Decision-1 都值得进入下一轮验证，本次 Jev 的时延更低；若以最低等待时间为主，阿里云百炼 值得继续验证，但它在一道数值比较题上出错。

仅 12 个独立人工示例；全部准确率配对区间包含零。这是本次服务表现，不是总体科学能力或纯模型推理速度排名。

01 / 四个模型的角色与关系

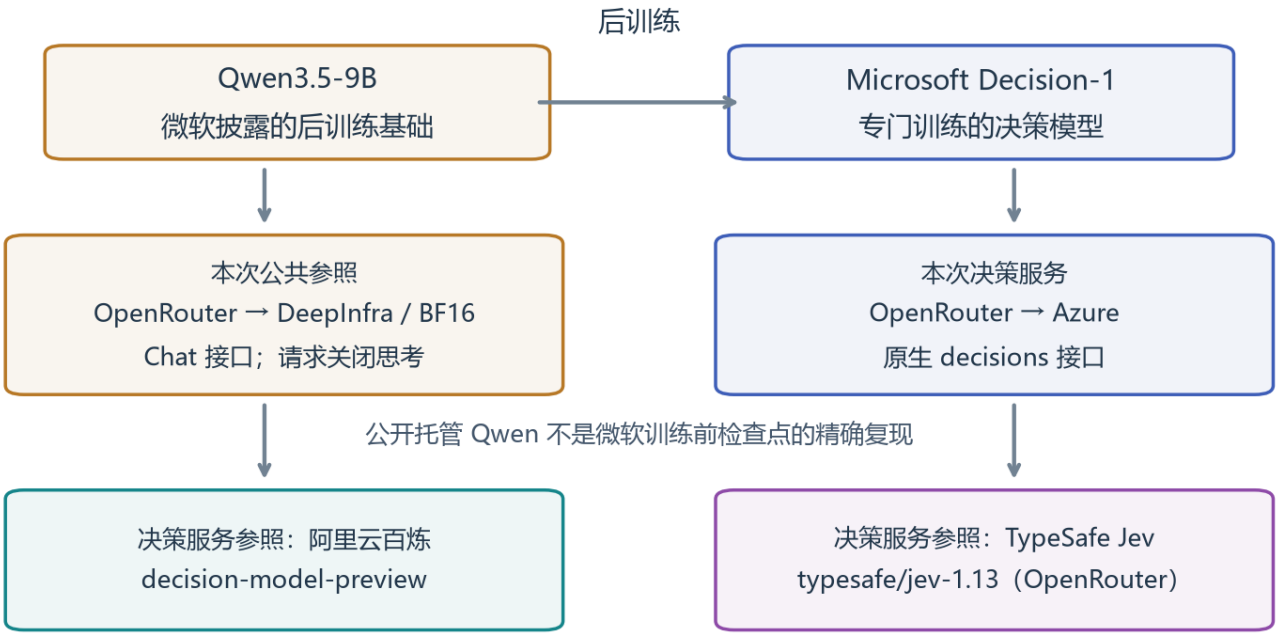


图 1. Qwen 是微软披露的后训练基础；百炼与 Jev 是另外两项决策服务参照。

保留 Qwen3.5-9B 是为了观察专门决策模型与公开基础模型参照的差异。纳入 Jev 则用于比较另一种决策服务在同一输入和评分条件下的表现。

服务	请求模型与入口
阿里云百炼	decision-model-preview；百炼 systemone 接口
微软 Decision-1	microsoft/microsoft-decision-1；OpenRouter decisions
Qwen3.5-9B	qwen/qwen3.5-9b；OpenRouter chat/completions
Jev 1.13	typesafe/jev-1.13；OpenRouter decisions

Jev 的接入范围

本次通过 OpenRouter 的 Decisions 接口调用 TypeSafe 的 Jev 决策模型，固定请求 1.13 版本，并记录接口返回的实际快照。它与微软走同一 OpenRouter 入口和同一把密钥，支持预定义选项的结构化决策；本次仅测试 Choice 三分类，不测试 Score 或 Noul。

微软与公开托管 Qwen 的硬件、接口、训练检查点及提示封装不同；服务差距不能全部归因于后训练。Jev 的结构和训练基础未在本次实验中验证。来源见第 14 页。

02 / 同次运行的测试设计

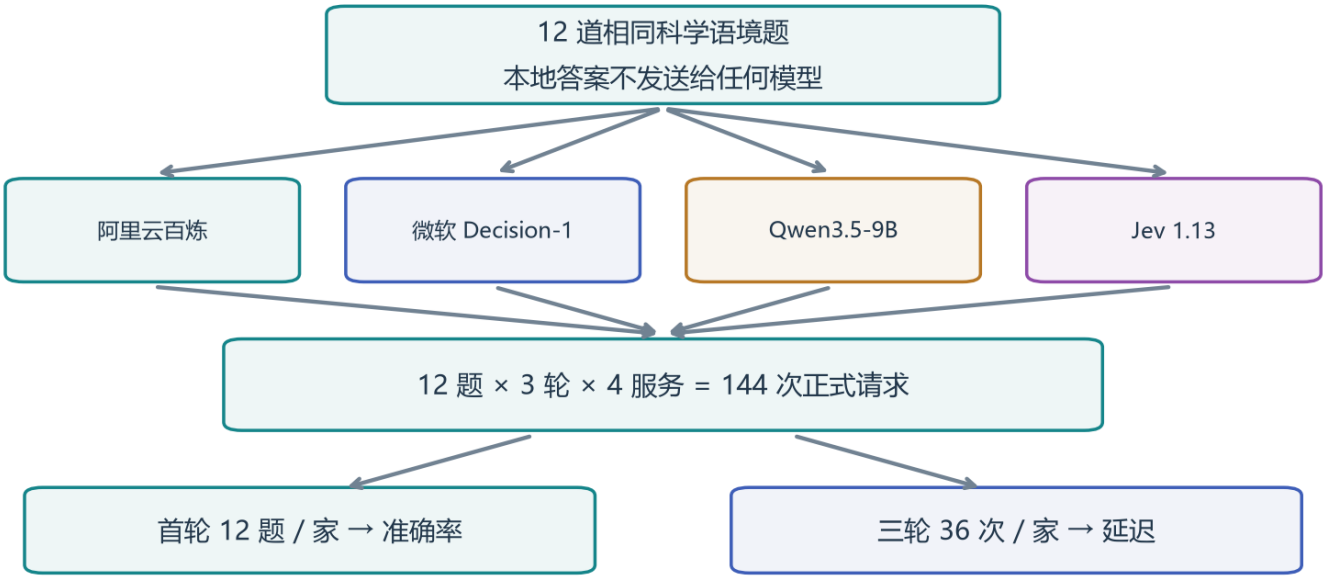


图 2. 每家另有 2 次暖机，共 152 条记录。暖机不计入准确率和主要延迟。

项目	实际设置
题目	12 个独立中文人工示例；物理、化学、生物各 4 条；三标签各 4 条
运行	3 轮；并发 1；种子 42；每题服务顺序随机；无自动重试
计时	HTTP 发出前至完整响应体接收；不含 JSON 解码、本地评分和请求间停顿
Qwen 适配	strict JSON schema；temperature=0；max_tokens=256；关闭思考；固定 DeepInfra BF16
评分	仅首轮算准确率；服务失败计为错误；后两轮统计延迟与重复一致性
总运行耗时	193.73 秒，包含暖机和停顿

四家使用相同 state 和 questions，标准答案仅保存在本地。Qwen 额外包含通用分类格式提示，且所有调用的 reasoning_tokens 为 0；因此结果对应本次关闭思考的 Chat 基线。

测试复用了长连接；未隔离云端缓存、硬件、网关和排队。所有输入均较短，本次没有评估长论文或高并发。

03 / 准确率与不确定性

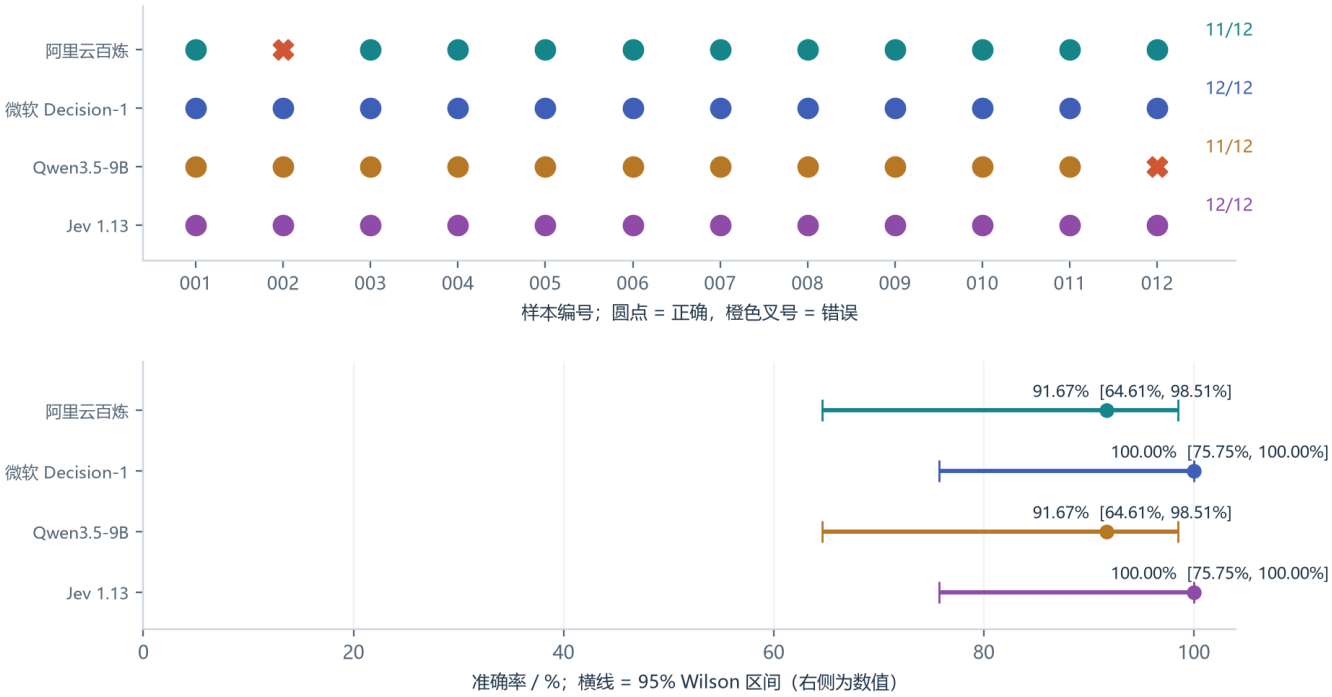


图 3. 每点代表一题；叉号为错误。下图为首轮准确率及 95% Wilson 区间。

配对差 左减右	差值 百分点	95% 配对区间
阿里云百炼 - 微软 Decision-1	-8.33	[-25.00, +0.00]
阿里云百炼 - Qwen3.5-9B	+0.00	[-25.00, +25.00]
阿里云百炼 - Jev 1.13	-8.33	[-25.00, +0.00]
微软 Decision-1 - Qwen3.5-9B	+8.33	[+0.00, +25.00]
微软 Decision-1 - Jev 1.13	+0.00	[+0.00, +0.00]
Qwen3.5-9B - Jev 1.13	-8.33	[-25.00, +0.00]

按输入 ID 进行 2,000 次配对 bootstrap；6 组比较未经多重校正。全部区间包含零，不能确认总体准确率差异。微软与 Jev 在本批题上逐题完全一致，产生退化的 [0,0] 区间；这不意味着两者在新题上必然等效。

04 / 分类错误与学科分布



图 4. 行为标准标签，列为预测标签；非对角线表示错误，每格为题数。

指标	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
合并 Macro-F1	0.9153	1.0000	0.9153	1.0000
物理	3 / 4	4 / 4	4 / 4	4 / 4
化学	4 / 4	4 / 4	4 / 4	4 / 4
生物	4 / 4	4 / 4	3 / 4	4 / 4

百炼错误为 demo-002，将数值冲突判为支持；Qwen 错误为 demo-012，将缺少目标测量判为反驳。微软和 Jev 首轮均无误判。

这些题测量的是记录与结论之间的关系；每科仅 4 条，不能代表物理建模、化学机制推断或生物专业研究能力。

05 / 响应速度与等待差距

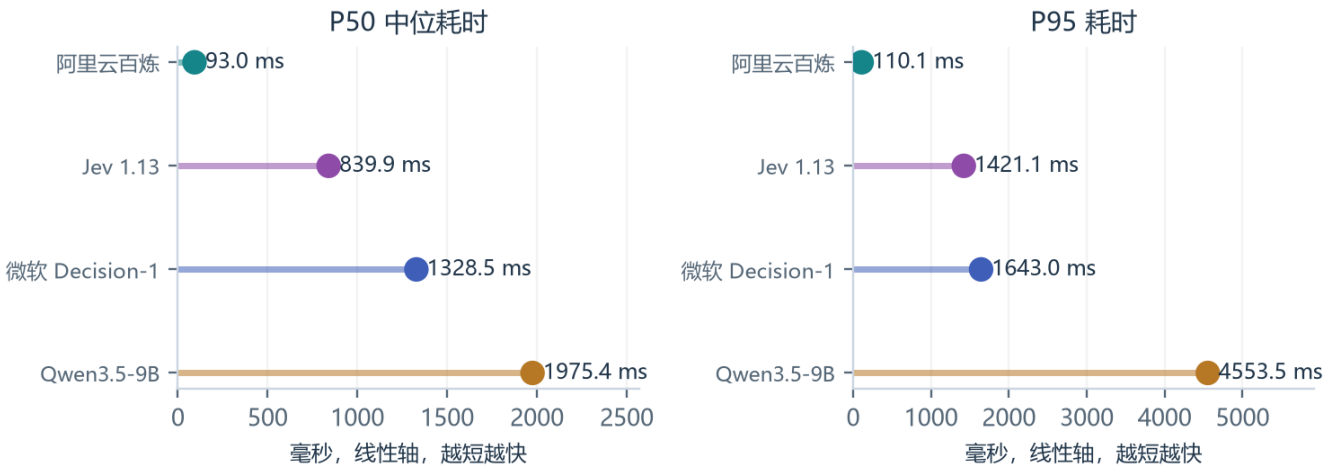


图 5. 每家 36 次正式请求，越短越快；点为分位值，线长仅示意。

比较 左侧更快	P50 耗时降低	P95 耗时降低
阿里云百炼 / Jev 1.13	88.92%	92.25%
阿里云百炼 / 微软 Decision-1	93.00%	93.30%
阿里云百炼 / Qwen3.5-9B	95.29%	97.58%
Jev 1.13 / 微软 Decision-1	36.77%	13.51%
Jev 1.13 / Qwen3.5-9B	57.48%	68.79%
微软 Decision-1 / Qwen3.5-9B	32.75%	63.92%

Jev 1.13 相对 微软 Decision-1 的 P50 减少 488.5 ms，P95 减少 221.9 ms。阿里云百炼 走国内直连，其余三家经 OpenRouter，网络路径不对等。

P95 为线性插值分位数，既不是最大耗时，也不是 SLA。比较包含网络、网关、排队和返回过程；没有把各厂商 server latency 当成统一指标。

06 / 延迟分布与同题比较

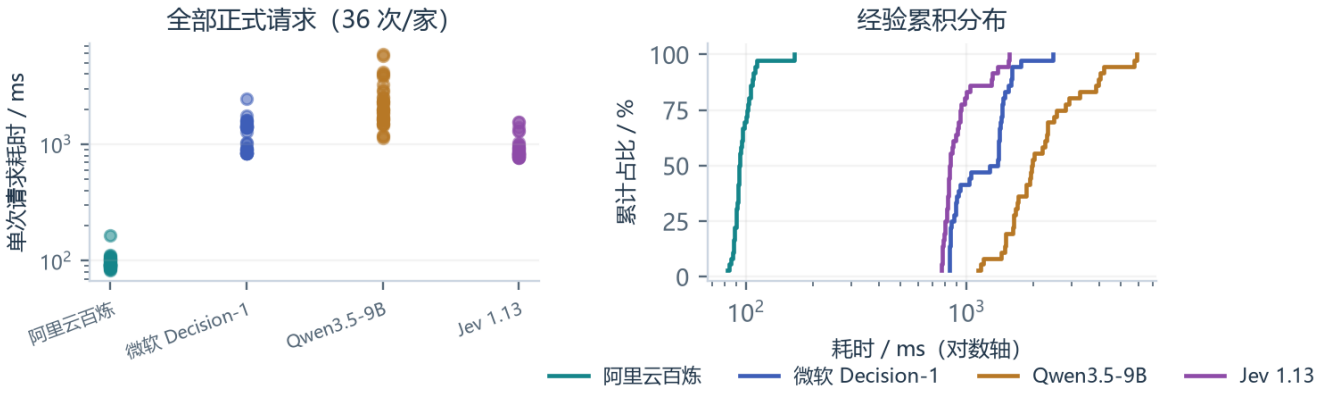


图 6. 左图展示全部正式请求（对数纵轴）；右图展示耗时的经验累积分布。

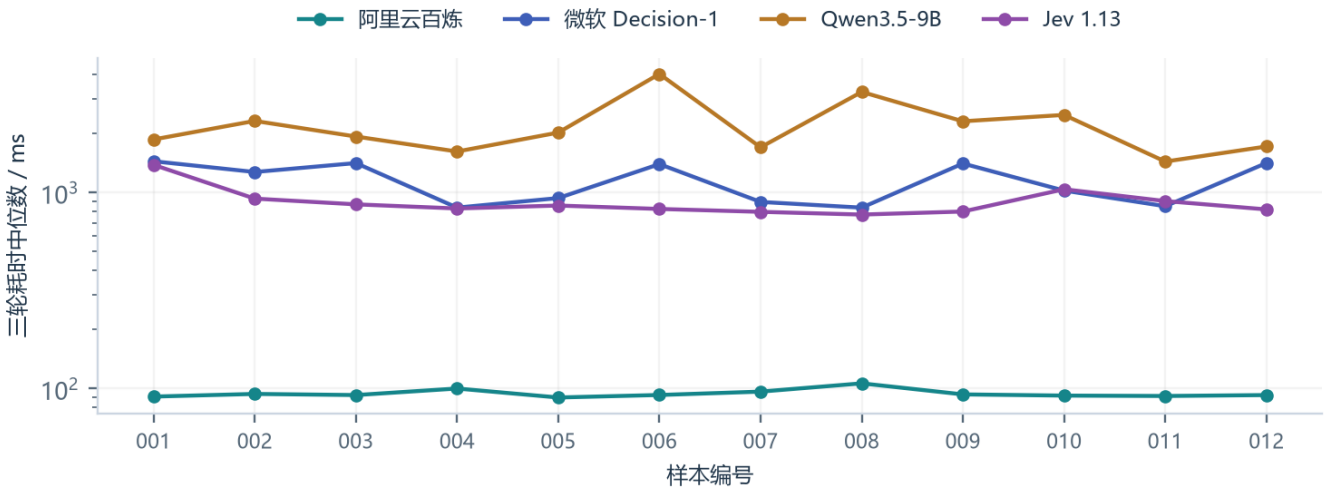


图 7. 每道题的三轮耗时中位数；图例颜色在整份报告中保持一致。

四家在本次运行呈现不同等待水平。每家 36 次全部成功，因此成功请求延迟与全部尝试延迟相同，不存在丢弃失败后使速度显得更快的问题。

未对尾部延迟进行显著性检验。重复输入可能被上游缓存，且本次测试只有一个时段、并发 1；不能外推到吞吐量或长期稳定性。

07 / 轮次变化与两道稳定错题

轮次 P50 ms	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
1	91.3	1421.4	2431.2	846.6
2	95.0	987.8	2147.5	844.4
3	91.8	1146.5	1647.1	832.5

demo-002 数值比较

结论：样品 A 的电阻大于样品 B。

记录：同温度下，A 电阻 2 Ω，B 电阻 7 Ω。

标准：反驳

服务	三轮结果	首轮所选概率
阿里云百炼	支持/支持/支持	1.0000
微软 Decision-1	反驳/反驳/反驳	0.9987
Qwen3.5-9B	反驳/反驳/反驳	N/A
Jev 1.13	反驳/反驳/反驳	1.0000

demo-012 证据缺失

结论：处理会改变基因表达量。

记录：本实验只测量了培养液 pH，没有测量基因表达。

标准：信息不足

服务	三轮结果	首轮所选概率
阿里云百炼	信息不足/信息不足/信息不足	0.9900
微软 Decision-1	信息不足/信息不足/信息不足	0.9147
Qwen3.5-9B	反驳/反驳/反驳	N/A
Jev 1.13	信息不足/信息不足/信息不足	1.0000

四家重复分类一致率均为 24/24；错误也保持稳定。输出稳定并不代表正确。数值关系可增加确定性规则；缺少测量应保留"信息不足"类别。

08 / 概率质量与自动处理阈值

指标	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
Brier 越低越好	0.176367	0.001237	不可用	0.006033
ECE 越低越好	0.100000	0.008535	不可用	0.016667
有效概率分布数	12 / 12	12 / 12	0 / 12	12 / 12

Qwen3.5-9B 不返回原生概率，未纳入本页两图

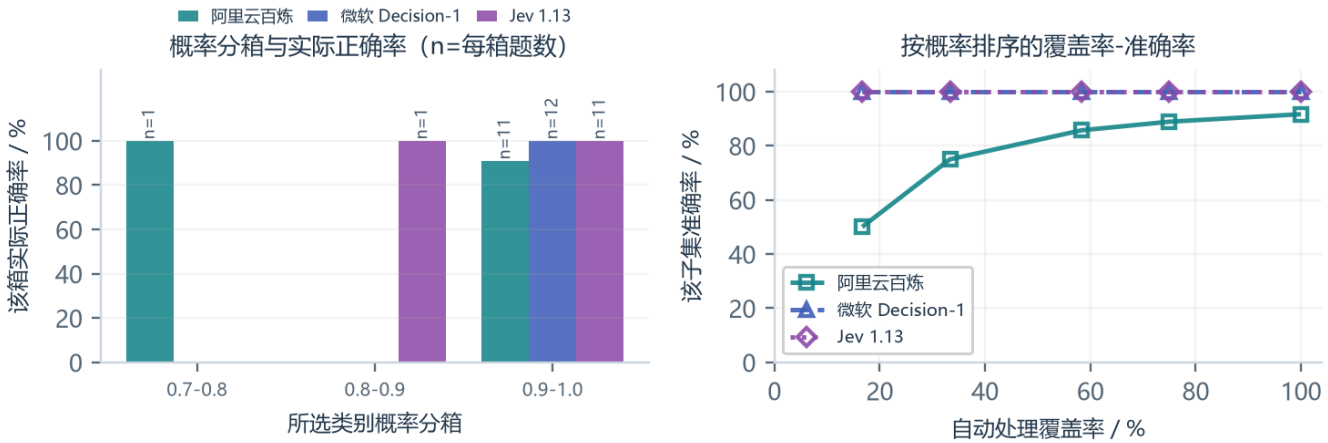


图 8. 左图为非空概率分箱的实际正确率，n 为该箱题数；右图按所选类别概率排序观察覆盖率与准确率。

百炼、微软与 Jev 返回原生概率分布；Qwen 本次只输出类别，不生成自报概率，也不人为补成 0/1 分布，其 Brier 和 ECE 留为不可用。

Brier 比较完整类别分布与标准答案；ECE 比较所选类别概率与分箱正确率。接口 confidence 的定义可能不同，报告没有直接用它跨厂商排名。

12 题不足以验证校准。微软与 Jev 都答对时，Brier/ECE 主要体现它们对本批正确答案的概率集中程度；不代表对未知题的风险估计更可靠。阈值应在独立开发集选择，再在测试集验证。

09 / 逐题审计 001 至 004

标准答案由本地测试集给出；以下为首轮输出。P 是所选类别概率；Qwen 未请求概率，记为 N/A。

demo-001 标准 支持

结论：样品 A 的电阻大于样品 B。

记录：同温度下，A 电阻 8 Ω，B 电阻 3 Ω。

模型	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
预测	支持	支持	支持	支持
P	1.0000	0.9998	N/A	1.0000

demo-002 标准 反驳

结论：样品 A 的电阻大于样品 B。

记录：同温度下，A 电阻 2 Ω，B 电阻 7 Ω。

模型	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
预测	支持	反驳	反驳	反驳
P	1.0000	0.9987	N/A	1.0000

demo-003 标准 信息不足

结论：样品 A 的电阻大于样品 B。

记录：测得样品 A 电阻 8 Ω，未测量 B。

模型	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
预测	信息不足	信息不足	信息不足	信息不足
P	0.7600	0.9997	N/A	1.0000

demo-004 标准 支持

结论：本次模拟已满足残差收敛标准。

记录：残差收敛标准为低于 1e-6；最终残差为 2e-8。

模型	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
预测	支持	支持	支持	支持
P	1.0000	0.9991	N/A	1.0000

10 / 逐题审计 005 至 008

标准答案由本地测试集给出；以下为首轮输出。P 是所选类别概率；Qwen 未请求概率，记为 N/A。

demo-005 标准 支持

结论：在记录的条件下，催化剂 X 的产率高于 Y。

记录：相同反应条件下，X 的产率 80%，Y 的产率 60%。

模型	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
预测	支持	支持	支持	支持
P	1.0000	0.9998	N/A	0.9900

demo-006 标准 反驳

结论：样品中检测到氯离子。

记录：检测报告明确记录：氯离子检测结果阴性。

模型	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
预测	反驳	反驳	反驳	反驳
P	0.9900	0.9993	N/A	1.0000

demo-007 标准 信息不足

结论：催化剂 X 比 Y 更耐长期使用。

记录：只记录了 X 与 Y 的首次反应产率，没有长期测试。

模型	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
预测	信息不足	信息不足	信息不足	信息不足
P	1.0000	0.9997	N/A	1.0000

demo-008 标准 反驳

结论：反应在 25 摄氏度完成。

记录：实验日志：恒温 60 摄氏度，反应结束；未进行 25 摄氏度实验。

模型	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
预测	反驳	反驳	反驳	反驳
P	0.9800	0.9875	N/A	0.8100

11 / 逐题审计 009 至 012

标准答案由本地测试集给出；以下为首轮输出。P 是所选类别概率；Qwen 未请求概率，记为 N/A。

demo-009 标准 支持

结论：处理组平均细胞数高于对照组。

记录：处理组平均细胞数 120，对照组平均细胞数 80。

模型	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
预测	支持	支持	支持	支持
P	1.0000	0.9999	N/A	1.0000

demo-010 标准 反驳

结论：实验使用了小鼠。

记录：实验记录明确说明仅使用酵母，未使用动物。

模型	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
预测	反驳	反驳	反驳	反驳
P	1.0000	0.9995	N/A	1.0000

demo-011 标准 信息不足

结论：处理可提高细胞存活率。

记录：记录只给出了处理组的荧光强度，没有存活率数据或对照。

模型	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
预测	信息不足	信息不足	信息不足	信息不足
P	1.0000	0.9998	N/A	1.0000

demo-012 标准 信息不足

结论：处理会改变基因表达量。

记录：本实验只测量了培养液 pH，没有测量基因表达。

模型	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
预测	信息不足	信息不足	反驳	信息不足
P	0.9900	0.9147	N/A	1.0000

12 / 结论边界与下一轮专业评测

本次可以支持的选择

在这 12 道中文证据判断题上，微软 Decision-1 与 Jev 1.13 准确率相同且首轮全对，本次 Jev 的 P50 与 P95 都更低；阿里云百炼 拥有最低等待时间，但出现一道数值误判；Qwen3.5-9B 在本次关闭思考的配置下少对一题且耗时最高。这个观察适合决定下一轮优先验证对象，不足以作为采购结论。

不能从本次推导的结论

本次不是专业科研能力排行榜，也不是微软后训练收益的因果实验。模型结构、上游硬件、精度、接口封装与网关不同；尚未评估长输入、高并发、跨时段变化、长尾失败、计费一致性或自动重试。百炼走国内直连而其余三家经 OpenRouter，延迟差中包含网络路径差异。

下一轮评测	建议设计
数据与标注	数百条起步，由专业人员核对；覆盖数值单位、反事实、信息缺失与长摘要
独立性	按论文、实验对象或来源分组划分开发集与测试集，防止同源泄漏
对照设置	增加确定性规则；Qwen 开启思考另设实验组，避免混入本次配置
运行条件	区分首次与重复输入，测试多个时间段、输入长度和并发等级；尽量对齐网络路径
统计与成本	预注册主要指标；六组比较预设校正方案；分开报告失败率、关键漏判与成本

准确率优先的流程可先评估微软和 Jev；时延敏感的流程可评估百炼加数值规则与人工复核。需要文字解释或开放式推理时，应另测生成模型任务，而不是让本次 Choice 测试替代。

新增诊断题应形成独立集合。不能反复修改当前测试题、针对错题调整提示后，再把同一批题的提高当成外部泛化收益。

13 / 复现记录与资料来源

```
cd D:\Decision\decision-benchmark
python benchmark.py --env-override run --providers bailian,microsoft,qwen,jev --rounds 3 --warmup 2 --concurrency 1
```

服务	实际返回模型	上游
阿里云百炼	decision-model-preview	None
微软 Decision-1	microsoft/microsoft-decision-1-20261009	Azure
Qwen3.5-9B	qwen/qwen3.5-9b	DeepInfra
Jev 1.13	typesafe/jev-1.13-20260917	TypeSafe

原始记录：D:\Decision\decision-benchmark\results\20261012T101454_247943Z

Python 3.12.6；requests 2.34.2；平台 Windows-11-10.0.26300-SP0；34 项离线测试通过；四方 6 组配对统计已校验。

request_payload 保留发送内容，raw_response 保留接口返回；无认证头。标准答案仅在本地数据中。每个新运行保存到新的时间戳目录。

文件	SHA-256
dataset.jsonl	f3cce6261ac63ce3d4bc22b18fd7af00 9a45142d6f039ff88d708da791cd9d88
requests.jsonl	eae0e7a84c372082cf4ff3ea5eee3ca9 eafa70e9247feb101ceff14efecb8297

指标口径

Accuracy = 首轮正确题数 / 12；Macro-F1 = 合并三类 F1 的算术平均；每家 P50/P95 使用 36 次正式请求和线性插值。暖机排除。延迟差为本次观察值，未估计置信区间。

官方资料

Jev 接入与版本（OpenRouter）：https://openrouter.ai/docs/guides/community/jev

微软发布及后训练基础：https://commandline.microsoft.com/microsoft-decision-1-model-foundry/

OpenRouter Qwen：https://openrouter.ai/qwen/qwen3.5-9b

阿里云百炼决策接口：https://help.aliyun.com/zh/model-studio/decision-model-api

实验日期 2026-10-12（北京时间）；运行目录 20261012T101454_247943Z。