真实 API 大样本评测 技术选型报告

PubMedQA 四方评测
可用于选型的结论

阿里云百炼 · 微软 Decision-1 · Qwen3.5-9B · Jev 1.13

2026-10-12 20:45 - 21:59（北京时间）· 6,000 次正式请求 · 耗时 74.1 分钟

结论：准确率首选 Jev 1.13 或 微软 Decision-1；最低时延 阿里云百炼

4/6 组两两配对区间不含零，首次具备选型效力。此前 12 题演示集为 0/6，无法判定优劣。

Jev 1.13 准确率 78.00%，微软 Decision-1 75.20%，两者差 2.80pp 且区间含零，统计上等效。

阿里云百炼 P50 仅 121.1 ms（最快），但准确率显著落后 13.60 个百分点。

指标	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
首轮准确率 越高越好	64.40%	75.20%	67.40%	**78.00%**
Macro-F1 越高越好	0.4841	0.6042	0.5716	**0.6430**
Brier 越低越好	0.5139	0.3553	不可用	**0.3366**
P50 ms 越低越好	**121.1**	525.9	1012.7	497.9
P95 ms 越低越好	**150.4**	1186.5	1966.1	1218.2
失败请求 越低越好	**0 / 1500**	**0 / 1500**	14 / 1500	**0 / 1500**
重复一致率	**100.00%**	98.00%	99.08%	98.20%

浅绿色为该行最优；并列最优同时标色。Qwen 不返回原生概率，其 Brier 为不可用，不参与该行比较。

PubMedQA 为公开数据集，题目可能已进入模型训练数据，绝对准确率可能偏高；跨模型相对比较受影响较小。

01 / 为什么要做大样本

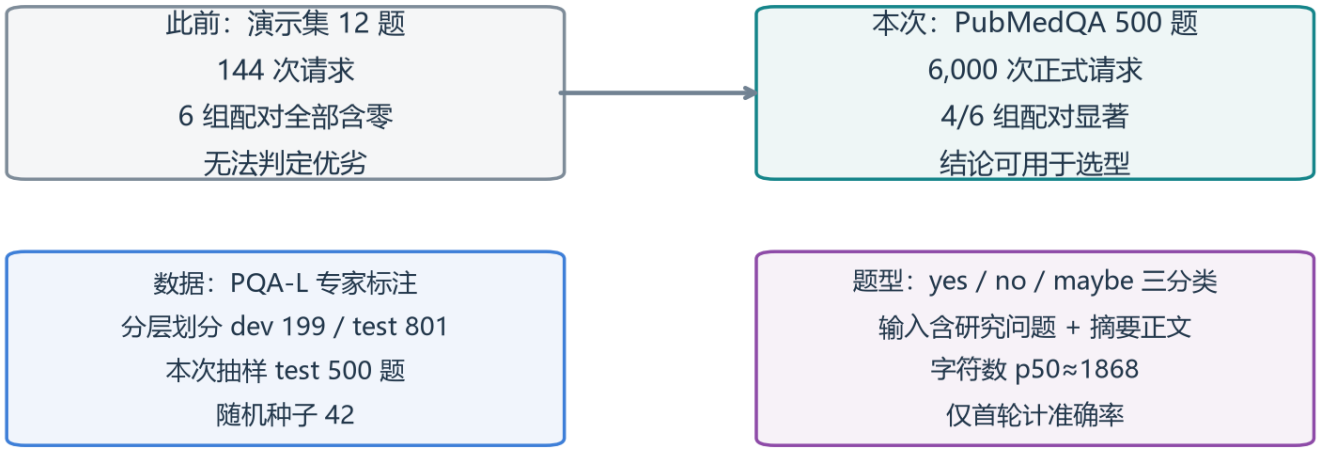


图 1. 从 12 题演示集升级到 500 题专家标注集，配对区间由全部含零变为多数可判定。

对比项	12 题演示集	本次 PubMedQA 500 题
正式请求数	144	6000
可判定配对	0 / 6	4 / 6
准确率区间宽度	约 50 个百分点	约 7–8 个百分点
能否用于选型	否，仅验证流程	是，但受第 13 页边界约束

小样本下即使准确率差 8.33 个百分点，配对区间仍覆盖零点，差异可能完全由抽样波动造成。500 题把区间收窄到可判定范围，才使「谁更准」成为统计结论而非观感。

样本量只解决抽样误差，不解决数据集代表性、训练数据污染和网络路径差异等系统性问题。

02 / 测试设计与公平性

项目	实际设置
数据集	PubMedQA PQA-L 专家标注；按标签分层划分 dev 199 / test 801；本次从 test 抽样 500
题型	yes / no / maybe 三分类；输入含研究问题与摘要正文，字符数 p50 约 1868
运行	3 轮；并发 1；种子 42；暖机 10 次/家；每题服务顺序随机
计时	HTTP 发出前至完整响应体接收；不含 JSON 解码、本地评分与请求间停顿
Qwen 适配	strict JSON schema；temperature=0；关闭思考；固定 DeepInfra BF16；仅返回类别键
评分	仅首轮算准确率；失败计为错误；后两轮用于延迟与重复一致性
阈值	在独立 dev 集选定 0.90，再到 test 验证，未用 test 成绩反推

标准答案从不发送给模型

导入器只把 QUESTION 与 CONTEXTS 放入请求，排除 LONG_ANSWER；final_decision 仅进入本地标准答案。四家收到完全相同的 state 与 questions。数据来源与文件哈希记录在 provenance.json。

测试复用长连接；未隔离云端缓存、硬件、网关与排队。百炼走国内直连，其余三家经 OpenRouter，网络路径不对等。

03 / 准确率与置信区间

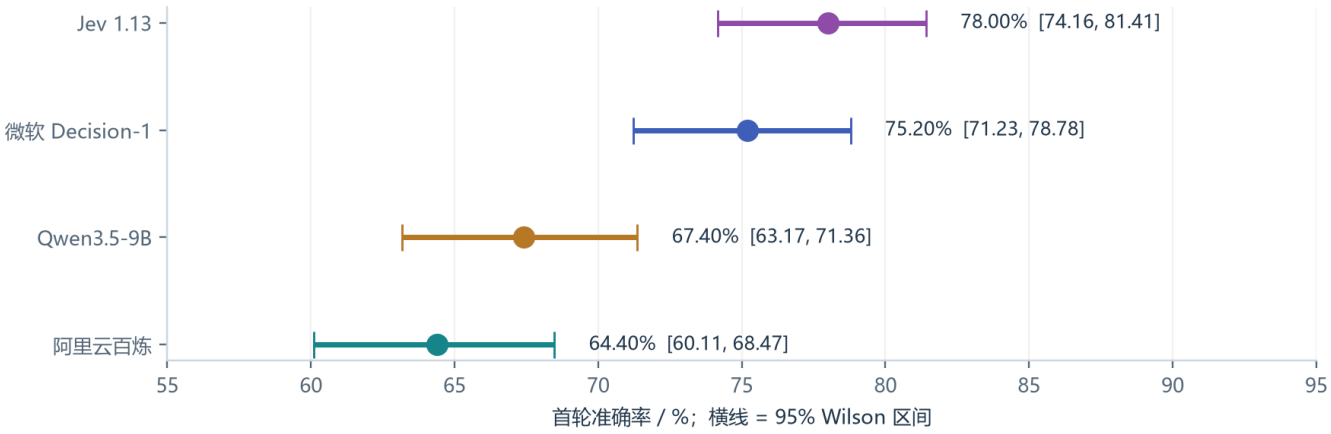


图 2. 首轮准确率及 95% Wilson 区间；区间已收窄到约 7–8 个百分点。

服务	首轮正确数	准确率	95% Wilson 区间	Macro-F1
Jev 1.13	390 / 500	78.00%	[74.16%, 81.41%]	0.6430
微软 Decision-1	376 / 500	75.20%	[71.23%, 78.78%]	0.6042
Qwen3.5-9B	337 / 500	67.40%	[63.17%, 71.36%]	0.5716
阿里云百炼	322 / 500	64.40%	[60.11%, 68.47%]	0.4841

Jev 1.13 与 微软 Decision-1 的区间大幅重叠，阿里云百炼 与 Qwen3.5-9B 的区间同样重叠；前两家与后两家之间则基本分离，这与下一页的配对检验一致。

Macro-F1 为三类 F1 的算术平均。PubMedQA 标签不均衡（yes 272 / no 178 / maybe 50），Macro-F1 会放大小类别的影响，应与第 5 页同读。

04 / 配对显著性：结论能否成立

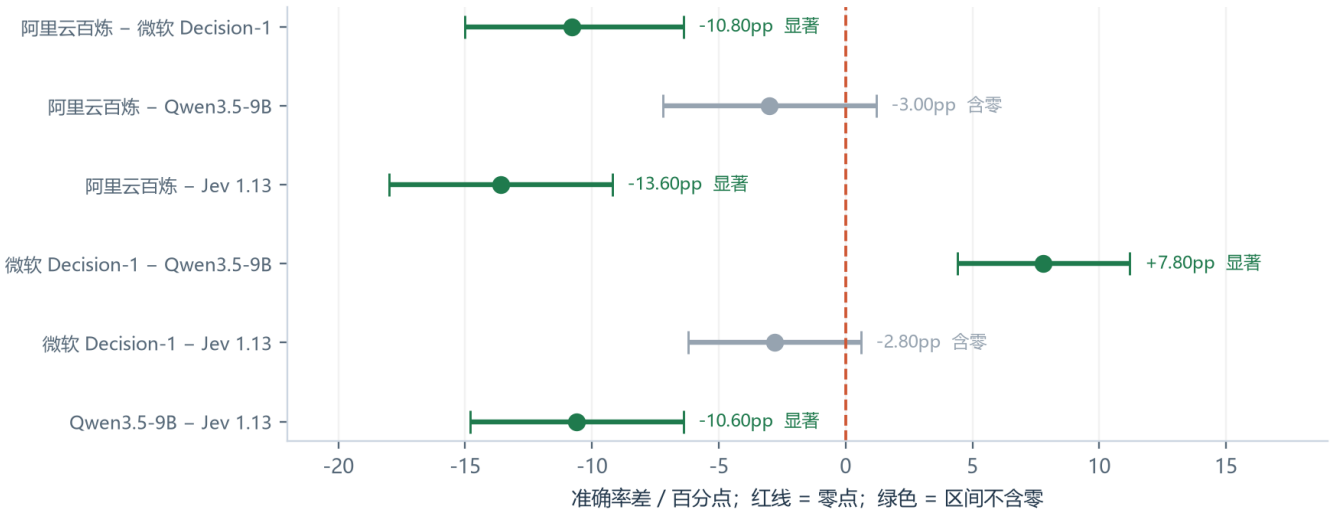


图 3. 六组两两配对的准确率差与 95% 区间；绿色为区间不含零的可判定对比。

配对 左减右	差值 百分点	95% 配对区间	判定
阿里云百炼 - 微软 Decision-1	-10.80	[-15.00, -6.40]	右显著更优
阿里云百炼 - Qwen3.5-9B	-3.00	[-7.20, +1.20]	含零，不显著
阿里云百炼 - Jev 1.13	-13.60	[-18.00, -9.20]	右显著更优
微软 Decision-1 - Qwen3.5-9B	+7.80	[+4.40, +11.20]	左显著更优
微软 Decision-1 - Jev 1.13	-2.80	[-6.20, +0.60]	含零，不显著
Qwen3.5-9B - Jev 1.13	-10.60	[-14.80, -6.40]	右显著更优

按输入 ID 聚类的 2,000 次配对 bootstrap；6 组比较未做多重校正，属探索性分析。微软与 Jev、百炼与 Qwen 两组区间含零，不能宣称其中任一方更准确。

05 / 错误结构与共性短板

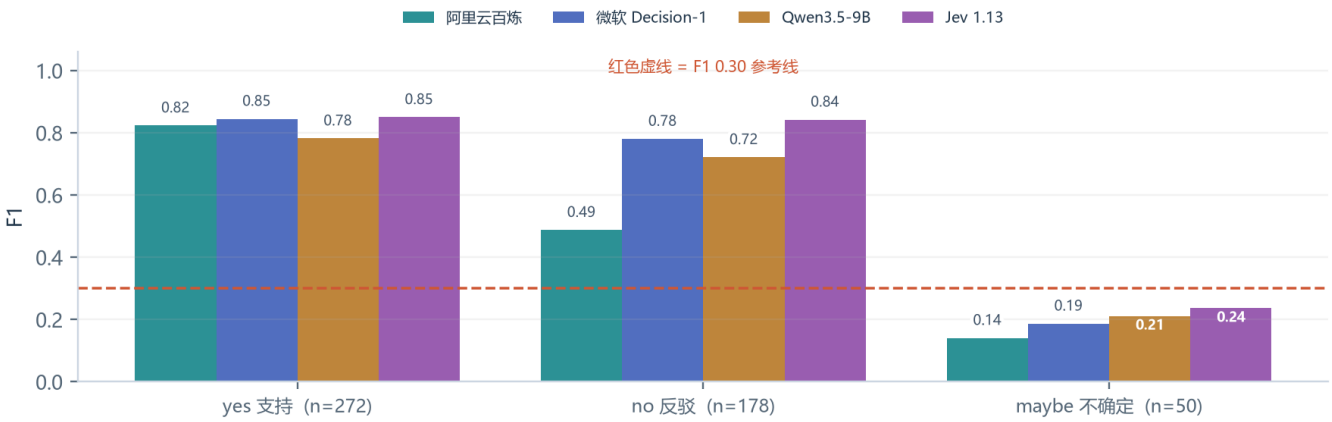


图 4. 分类别 F1；红线为 0.30 参考线。四家在 maybe 类上全部低于该线。

类别 / 样本数	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
yes 支持 n=272	0.824	0.845	0.782	0.850
no 反驳 n=178	0.488	0.781	0.722	0.842
maybe 不确定 n=50	0.141	0.187	0.211	0.236
Macro-F1	0.4841	0.6042	0.5716	0.6430

共性短板：maybe 类全线失效

四家在「证据不足 / 不确定」类的 F1 分别为 0.141、0.187、0.211、0.236，全部低于 0.24。这是决策模型品类的共性问题，不是某一家的缺陷。生产含义：凡涉及「证据是否充分」的判断，都不应交给模型自动裁决，必须人工复核或规则兜底。

另一处结构性风险：阿里云百炼 的 no 类召回仅 33.7%，即大量「反驳」被判成「支持」。在需要识别否定结论的场景风险显著，这也是其 Macro-F1 最低的主因。

06 / 混淆矩阵逐家对照

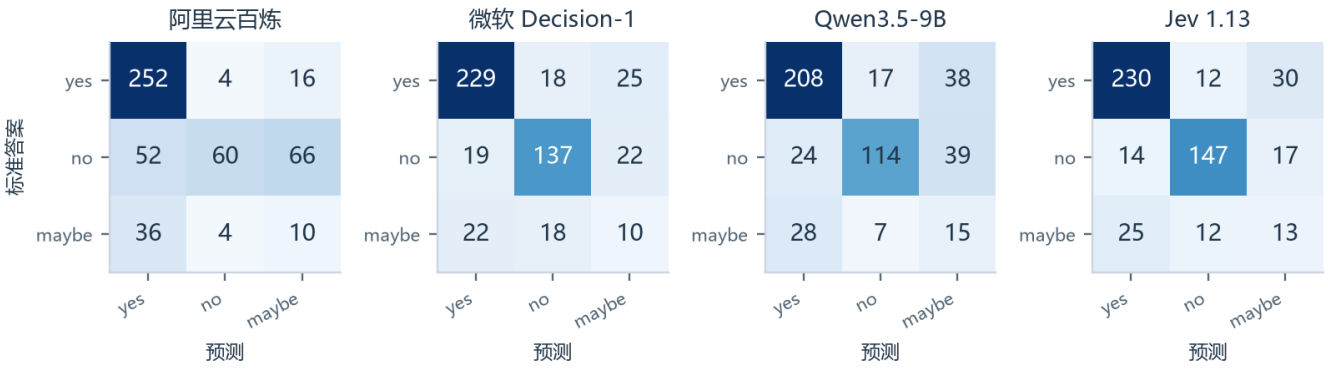


图 5. 行为标准答案，列为预测；非对角线为错误，每格为题数（首轮 500 题）。

矩阵显示四家的错误并非随机分布：maybe 行几乎没有被正确命中，多数被判为 yes 或 no；阿里云百炼 的 no 行有大量流向 yes。这说明模型倾向给出明确结论，而不愿输出「不确定」。

每格为题数而非比例；各类别样本量不同（yes 272 / no 178 / maybe 50），比较召回时应结合第 6 页的分类别 F1。

07 / 响应速度与稳定性

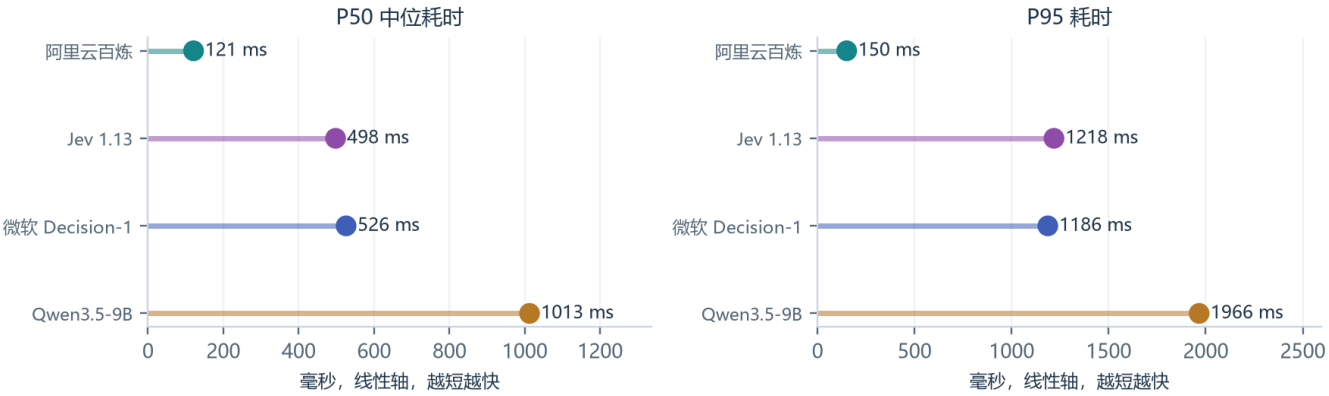


图 6. P50 与 P95 耗时（线性轴，越短越快）；仅统计成功的正式请求。

比较 左侧更快	P50 耗时降低	P95 耗时降低
阿里云百炼 / Jev 1.13	75.68%	87.65%
阿里云百炼 / 微软 Decision-1	76.98%	87.32%
阿里云百炼 / Qwen3.5-9B	88.05%	92.35%
Jev 1.13 / 微软 Decision-1	5.31%	-2.68%
Jev 1.13 / Qwen3.5-9B	50.83%	38.04%
微软 Decision-1 / Qwen3.5-9B	48.07%	39.65%

轮次 P50 ms	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
1	121.8	458.0	931.9	421.0
2	120.3	542.7	942.0	516.0
3	121.1	621.7	1209.0	623.7

三轮 P50 未见持续漂移。阿里云百炼 的领先包含国内直连与跨境 OpenRouter 的路径差异，不能等同于模型本身更快。

P95 为线性插值分位数，不是最大耗时也不是 SLA。本次仅并发 1、单一时段，不能外推到吞吐量或长期稳定性。

08 / 失败与可用性风险

服务	成功 / 总数	失败率	超时	失败原因
阿里云百炼	1500 / 1500	0.00%	0	无
微软 Decision-1	1500 / 1500	0.00%	0	无
Qwen3.5-9B	1486 / 1500	0.93%	0	HTTP 429 上游限流（DeepInfra 共享池 engine_overloaded） 共 14 次
Jev 1.13	1500 / 1500	0.00%	0	无

Qwen3.5-9B 出现 14 次失败，全部为 OpenRouter 共享池上游限流，属可用性问题而非模型能力问题。但它提示：依赖共享池路由的服务在批量负载下存在限流风险，生产部署应自备上游密钥或指定专用 provider。其余三家零失败。

程序不自动重试，失败按错误计入准确率分母；同时报告仅成功响应子集的准确率，避免隐藏慢失败。

09 / 概率质量与风险曲线

指标	阿里云百炼	微软 Decision-1	Qwen3.5-9B	Jev 1.13
Brier 越低越好	0.5139	0.3553	不可用	0.3366
ECE 越低越好	0.1700	0.1058	不可用	0.1181
有效概率分布数	500 / 500	500 / 500	0 / 500	500 / 500

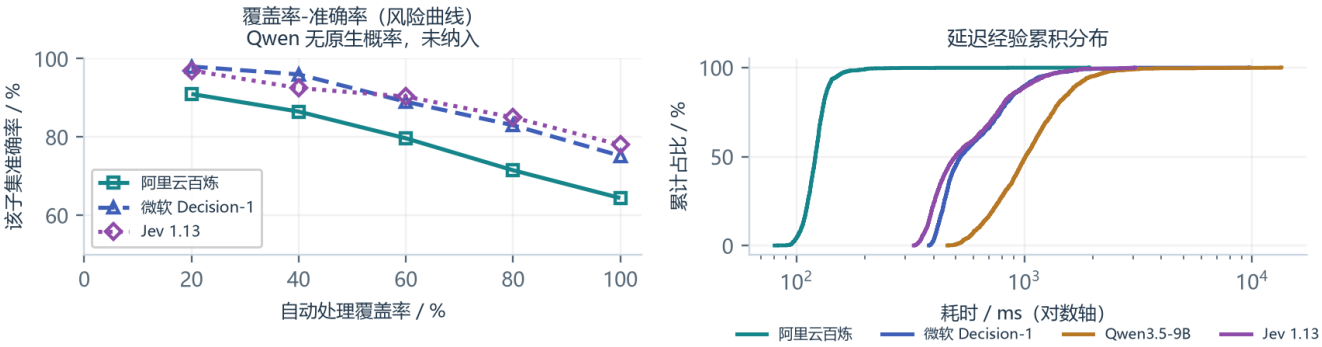


图 7. 左：按所选类别概率排序的覆盖率-准确率曲线；右：延迟经验累积分布。

Jev 1.13 的 Brier 最低，微软 Decision-1 的 ECE 最低，两者校准质量接近；阿里云百炼 的 Brier 与 ECE 明显偏高，其置信度可靠性较弱。Qwen3.5-9B 只输出类别、不自报概率，也不人为补成 0/1 分布，故概率指标为不可用。

Brier 为多分类平方误差求和（三分类范围 0–2）；ECE 使用 10 个等宽分箱，采用「被选中类别的概率」而非厂商 confidence 作为共同口径。

10 / 生产阈值：dev 选定到 test 验证

Qwen3.5-9B 不返回原生概率，无法设阈值，未纳入本页两图

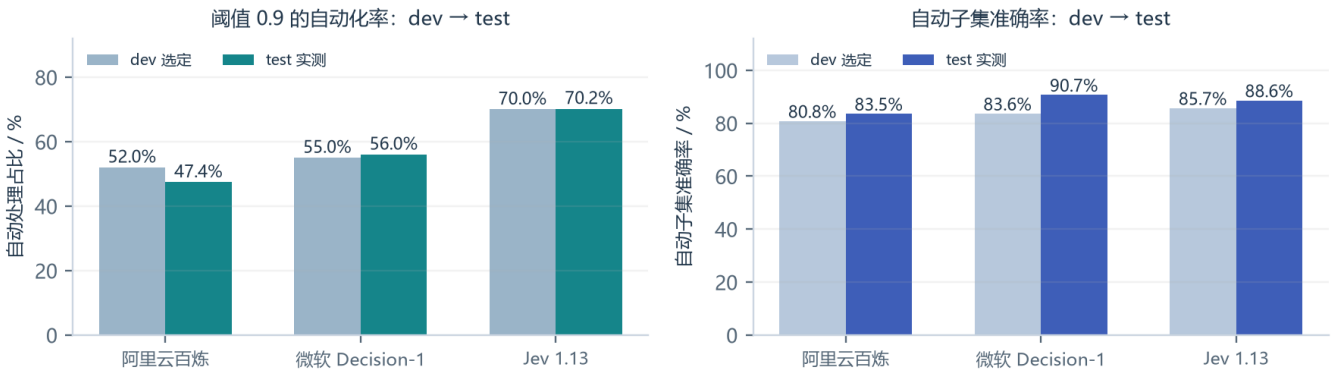


图 8. 阈值 0.90 在 dev 选定后到 test 的实际表现；两侧纵轴均自零起。

服务	自动占比 dev	自动占比 test	准确率 dev	准确率 test	test 需人工	自动集错误
阿里云百炼	52.0%	47.4%	80.8%	83.5%	52.6%	39
微软 Decision-1	55.0%	56.0%	83.6%	90.7%	44.0%	26
Jev 1.13	70.0%	70.2%	85.7%	88.6%	29.8%	40

阈值在独立 dev 集（100 题）选定为 0.90，再到 test 验证，未用 test 成绩反推。Jev 1.13 的自动占比偏差仅 0.2 个百分点，阈值可迁移性良好，可直接用于生产配置。

要最高自动化率选 Jev 1.13：test 上自动处理 70.2%，仅 29.8% 需人工；要最低自动错误选 微软 Decision-1：自动子集准确率 90.7%，自动集错误 26 个（三家最低）。

覆盖率结果是测试集的描述性统计，上线前应在自有业务样本上重新标定阈值，并对 maybe 类单独设兜底规则。

11 / 成本与计费口径

服务	6,000 次请求输入 token	相对量	成本口径
阿里云百炼	611,472	1.00×	按各平台实际计费
微软 Decision-1	616,896	1.01×	≈ $0.0259 @ $0.042/M，输出免费
Qwen3.5-9B	758,434	1.24×	按各平台实际计费
Jev 1.13	1,089,447	1.78×	≈ $0.0458 @ $0.042/M，输出免费

Jev 1.13 的 token 计数约为 微软 Decision-1 的 1.77 倍（分词口径不同），同价下单位成本更高；但由于输出免费，本次全量评测的 OpenRouter 侧成本仍在美分量级。

token 数取各服务自报用量，口径可能不一致，不能直接当作输入长度比较。百炼与 Qwen 的实际价格随平台与上游浮动，本页不替其报价。

12 / 选型建议与结论边界

场景	推荐	依据
准确率优先	Jev 1.13 或 微软 Decision-1	78.0% / 75.2%，显著优于另两家；二者间不显著
追求最少人工	Jev 1.13	阈值 0.90 下自动化 70.2%，人工量仅 29.8%
自动错误代价高	微软 Decision-1	自动子集准确率 90.7%，自动集错误 26 个最低
毫秒级实时链路	阿里云百炼	P50 121.1 ms、重复一致率 100.00%；须接受准确率落后
不建议做生产决策	Qwen3.5-9B	准确率中游、延迟最高、无原生概率，且遇上游 429 限流

推荐部署形态

Jev 1.13 或 微软 Decision-1 作主决策 + 置信度 0.90 分流 + maybe 类与低置信统一转人工；阿里云百炼 可作延迟敏感场景的前置粗筛，但需叠加否定结论的规则校验。

本次仍不能外推的部分

一、PubMedQA 为公开数据集，题目可能已进入各模型训练数据，绝对准确率可能偏高，相对比较受影响较小；结论应以新收集并独立标注的样本复核。二、延迟不可直接跨家比较：百炼国内直连，其余三家经 OpenRouter 跨境路由。三、仅测 choice 三分类，未覆盖 Score / Noul 题型、长文档、高并发、跨时段稳定性与计费一致性。四、6 组配对未做多重比较校正；maybe 类仅 50 例，其 F1 区间很宽。

各厂商公布的自测指标仍缺独立第三方验证，本报告只以本次实测为准，不得作为厂商能力的最终排名引用。

13 / 复现记录与资料来源

```
cd D:\Decision\decision-benchmark

python benchmark.py prepare-pubmedqa

python benchmark.py --env-override run --dataset data/pubmedqa/test.jsonl --limit 500 --rounds 3 --warmup 10 --concurrency 1 --seed 42 --providers bailian,microsoft,qwen,jev
```

服务	实际返回模型	上游
阿里云百炼	decision-model-preview	None
微软 Decision-1	microsoft/microsoft-decision-1-20261009	Azure
Qwen3.5-9B	qwen/qwen3.5-9b	DeepInfra
Jev 1.13	typesafe/jev-1.13-20260917	TypeSafe

原始记录：D:\Decision\decision-benchmark\results\20261012T124545_166990Z

文件	SHA-256
dataset.jsonl	f6e2f702bf6a856b20fcf9922c57aaaf ec8a78dd99f37e693ea308e0d00911cd
requests.jsonl	0ef5048a0b5d9cec5df130ddfe524c99 b4f604885226436ce0b99e010847618b

Python 3.12.6；requests 2.34.2；平台 Windows-11-10.0.26300-SP0；2,000 次配对 bootstrap；34 项离线测试通过。

request_payload 保留发送内容，raw_response 保留接口返回，均不含认证头；百炼 workspace 子域在产物中脱敏。标准答案仅存于本地数据。每个新运行写入新的时间戳目录，不覆盖历史。

指标口径

Accuracy = 首轮正确题数 / 500；Macro-F1 = 三类 F1 的算术平均；P50/P95 使用每家 1500 次正式请求与线性插值，暖机排除；配对 bootstrap 按样本 ID 聚类重采样。

资料来源

PubMedQA 论文：https://aclanthology.org/D19-1259/

PubMedQA 作者仓库：https://github.com/pubmedqa/pubmedqa

Jev 接入（OpenRouter）：https://openrouter.ai/docs/guides/community/jev

微软发布说明：https://commandline.microsoft.com/microsoft-decision-1-model-foundry/

阿里云百炼决策接口：https://help.aliyun.com/zh/model-studio/decision-model-api

实验日期 2026-10-12（北京时间）；运行目录 20261012T124545_166990Z。